

Probabilità e statistica

Nicolò Giuliani

Indice

1	Spazi di probabilità	3
1.1	Teoria degli insiemi	3
1.2	Modello matematico di un esperimento aleatorio	4
1.3	Assiomi della probabilità	5
1.4	Conseguenze degli assiomi	6
2	Probabilità codizionata e indipendenza	7
2.1	Regola della catena	9
2.2	Eventi indipendenti	9
2.3	Formula delle probabilità totali	10
2.4	Formula di Bayes	11
3	Calcolo combinatorio	11
3.1	Cardinalità e corrispondenza biunivoca	11
3.2	Fattoriale e coefficiente binomiale	12
3.3	Metodo delle scelte successive	12
3.4	Disposizioni e combinazioni	13
3.5	Variabili aleatorie	14
3.5.1	Distribuzione di una variabile aleatoria	15
3.5.2	Funzione di ripartizione (CDF)	16
4	Variabili aleatorie discrete	17
4.1	Caratterizzazione delle variabili aleatorie discrete	19
4.2	Indici di sintesi di una distribuzione: μ e σ^2	19
4.2.1	Media o valore atteso	19
4.2.2	Varianza	20
4.3	Distribuzioni discrete notevoli	20
5	Variabili aleatorie continue	22
5.1	Definizioni di densità continua e v.a. continua	23
5.1.1	Dalla funzione di ripartizione alla densità continua	24
5.1.2	Funzioni di variabili aleatorie continue	24
5.2	Indici di sintesi di una distribuzione: μ e σ^2	24
5.2.1	Media o valore atteso	24
5.2.2	Varianza	25
5.3	Distribuzioni continue notevoli	25

6	Vettori aleatori	28
6.1	Introduzione	28
6.1.1	Distribuzione o legge di un vettore aleatorio	28
6.1.2	Indipendenza di variabili aleatorie	29
6.2	Vettori aleatori discreti	29
6.2.1	Densita' discreta congiunta e densita' discrete marginali	30
6.2.2	Indipendenza e densita' discreta congiunta	30
6.3	Valore atteso e varianza di una funzione di (X, Y)	31
6.4	Indici di sintesi della distribuzione di un vettore aleatorio discreto	31
6.5	Statistica descrittiva e teoremi limite	32
6.5.1	Statistica descrittiva	32
6.5.2	Le frequenze: tabelle e grafici	32
6.5.2.1	Classi di frequenza	32
6.5.2.2	Indici	33
6.5.2.3	Indici di dispersione	33
6.5.3	Dati bivariati: correlazione e regressione	34
6.5.3.1	Insiemi di dati bivariati e frequenza congiunta	34
6.5.3.2	Coefficiente di correlazione lineare	35
6.5.3.3	Metodo dei minimi quadrati e regressione lineare	36
6.5.4	Teoremi limite	37
6.5.4.1	Successioni di variabili aleatorie i.i.d.	38
6.5.4.2	Legge dei grandi numeri (LGN)	38
6.5.4.3	Metodo Monte Carlo	39
6.5.4.4	Metodo del gradiente stocastico	40
6.5.4.5	Metodo del gradiente stocastico	40
6.5.4.6	Teorema centrale del limite (TCL)	41
7	Catene di Markov	41
7.1	Processi stocastici	41
7.2	Catene di Markov a tempo discreto	42
7.3	Catene di Markov omogenee e a stati finiti	42
7.3.1	Probabilita' di transizione in piu' passi	44
7.3.2	Classi comunicanti	45
7.3.3	Legge di X_n	46
7.3.4	Distribuzione invariante	46
7.3.5	Interpretazione della distribuzione invariante	47
7.3.6	Google e l'algoritmo PageRank	48
7.3.7	Esistenza e unicit� della misura invariante	48
7.4	Classificazione degli stati	48
7.4.1	Problemi di assorbimento	49

1 Spazi di probabilità

Con *probabilità* intendiamo la misura della certezza assoluta che un evento si verifichi o no. In matematica attribuiamo un valore compreso tra $[0, 1]$ come intervallo tra il *falso* e il *vero*.

- $\mathbb{P} = 0$ significa che con certezza assoluta la proposizione è *falsa*.
- $\mathbb{P} = 1$ significa che con certezza assoluta la proposizione è *vera*.
- $\mathbb{P} \in (0, 1)$ significa che la proposizione è probabile, più $\mathbb{P}(A)$ è vicina ad 1 più è probabile che l'evento A avvenga.

Come calcoliamo la probabilità di un evento? Abbiamo due modi di interpretazione

- Approccio *bayesano*: Si prendono tutte le informazioni che abbiamo a disposizione e arriviamo ad una assegnazione iniziale tramite generalmente simmetrie.
- Approccio *frequentista*: Ripetiamo l'esperimento per ottenere un *campione* di dati da analizzare tramite gli strumenti della statistica descrittiva.

$$\mathbb{P}(A) \approx \frac{n \text{ volte che si verifica } A}{n}$$

Generalmente sono pochi i casi in cui si preferisce l'approccio bayesano perchè questo è molto difficile da applicare in problemi dove la simmetria non è ben definita o il problema non è ripetibile. Nella realtà gli esperimenti fisici possono essere ripetuti e l'approccio frequentista è la preferita. In ogni caso però le *inferenze* (conclusioni) vanno validate con gli strumenti della statistica inferenziale.

Possiamo riassumere che

- Che cos'è la probabilità? *Filosofia*
- Come si stima la probabilità? *Statistica*
- Quali assiomi verifica la probabilità? *Matematica*

Per ora concentriamoci su quest'ultimo.

1.1 Teoria degli insiemi

Possiamo definire matematicamente un evento come un insieme.

Dato Ω un insieme e ω un suo elemento, quindi

$$\omega \in \Omega$$

$$\emptyset \in \Omega$$

$$\Omega \in \Omega$$

Definiamo **cardinalità** (numero di elementi) con

$$|\Omega|$$

oppure

$$\#\Omega$$

Definiamo l'insieme delle parti $\mathcal{P}(A)$ ovvero l'insieme di tutti i sottoinsiemi di Ω (insieme di insiemi).

$$\Omega = \{1, 2\}$$

$$\mathcal{P}(\Omega) = \{\emptyset, \Omega, \{1\}, \{2\}\}$$

e la sua cardinalità

$$|\mathcal{P}(\Omega)| = 4$$

Operazioni insiemistiche Ricordiamo unione, intersezione e complementazioni

$$A \cup B = \{\omega \in \Omega : \omega \text{ appartiene ad almeno uno tra } A \text{ o } B\}$$

$$A \cap B = \{\omega \in \Omega : \omega \text{ appartiene sia ad } A \text{ e } B\}$$

$$A^c = \{\omega \in \Omega : \omega \text{ non appartiene ad } A\}$$

$$B \setminus A = \{\omega \in B : \omega \text{ non appartiene ad } A\}$$

Ricordiamo anche le **leggi di De Morgan**:

- per due insiemi

$$(A \cup B)^c = A^c \cap B^c$$

$$(A \cap B)^c = A^c \cup B^c$$

Ricordiamo le **proprietà distributive**

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$$

Unioni e intersezioni infinite Si dice $A_1, \dots, A_n$ *famiglia numerabile* o *successione* di sottoinsiemi di Ω , definiamo

$$\bigcup_{n=1}^{\infty} A_n = \{\omega \in \Omega : \omega \in A \text{ per almeno un } n\}$$

$$\bigcap_{n=1}^{\infty} A_n = \{\omega \in \Omega : \omega \in A \text{ per ogni un } n\}$$

Anche per questo vengolo applicate le leggi di De Morgan.

1.2 Modello matematico di un esperimento aleatorio

Un **esperimento aleatorio** (fenomeno aleatorio/prova/situazione d'incertezza) è un esperimento che non conosciamo con certezza il risultato. Un **esito** è un suo ipotetico risultato.

Ora definiamo matematicamente:

Definizione: Un **evento** è una affermazione riguardante l'ipotetico risultato dell'esperimento di cui possiamo dire con certezza se è vero o falso una volta noto l'esito del esperimento. Gli esiti per un evento vero si chiamano *casi favorevoli* gli altri si chiamano casi contari.

Un evento lo definiamo con una lettera maiuscola:

$$A = \text{" esce un numero pari"}$$

Il **modello matematico** di un esperimento aleatorio è una descrizione sintetica dell'esperimento stesso attraverso la teoria degli insiemi.

Definizione: Definiamo **spazio campionario** un insieme che contiene tutti gli ipotetici risultati dell'esperimento. Lo definiamo con Ω . Un suo qualunque esito lo definiamo con ω .

Definizione: Ogni evento (affermazione) è rappresentato da quel sottoinsieme di Ω che contiene i casi favorevoli (esiti per cui evento è sempre vero). Un qualunque sottoinsieme di Ω lo chiameremo ancora evento.

Quindi il termine evento indica sia il sottoinsieme che l'affermazione, utilizzeremo anche lo stesso simbolo (lettera maiuscola). Alcuni eventi hanno nomi specifici:

- *Evento certo* è l'insieme Ω , affermazione sempre vera qualunque sia l'esito.
- *Evento impossibile* è l'insieme $\emptyset$, affermazione sempre falsa qualunque sia l'esito.
- *Evento elementare* è un sottoinsieme di Ω che contiene un solo elemento, corrisponde ad un'affermazione che è vera per un solo esito.

Come abbiamo visto gli eventi sono descritti sia da affermazioni che da insiemi. Sulle affermazioni possiamo eseguire le operazioni date dai *connettivi logici* alle quali corrispondono alle relative *operazioni insiemistiche*.

CONNETTIVI LOGICI	OPERAZIONI/RELAZIONI INSIEMISTICHE
Disgiunzione $A \text{ o } B$	Unione $A \cup B$
Congiunzione $A \text{ e } B$	Intersezione $A \cap B$
Negazione non A	Complementazione A^c
Implicazione $A \Rightarrow B$	Inclusione $A \subset B$
Doppia implicazione $A \Leftrightarrow B$	Uguaglianza $A = B$

1.3 Assiomi della probabilità

Assioma I. A ciascun sottoinsieme (o evento) A di Ω è assegnato un numero $\mathcal{P}(A)$ che verifica

$$0 \leq \mathcal{P}(A) \leq 1$$

Tale numero $\mathcal{P}(A)$ si chiama **probabilità** di A .

Assioma II. $\mathbb{P}(\Omega) = 1$

Assioma III. Vale la proprietà di **addittività numerabile**: Sia $A_1, A_2, \dots, A_n$ una successione di sottoinsiemi di Ω tra loro disgiunti e sia

$$A = \bigcup_{n=1}^{\infty} A_n$$

Allora

$$\mathbb{P}(A) = \bigcup_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$$

Quindi la probabilità $\mathbb{P}$ è una funzione che ad ogni sottoinsieme A di Ω fa corrispondere un numero in $[0, 1]$:

$$A \in \mathcal{P}(\Omega) \rightarrow \mathbb{P}(A) \in [0, 1]$$

dove $\mathcal{P}$ è l'insieme delle parti di Ω ed è il dominio, mentre il codominio è $[0, 1]$:

$$\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1]$$

Una probabilità $\mathbb{P}$ si dice **discreta** se assume un numero finito di valori.

Definizione: La coppia $(\Omega, \mathbb{P})$ si dice **spazio di probabilità** o modello matematico dell'esperimento aleatorio.

1.4 Conseguenze degli assiomi

Teorema: Sia $(\Omega, \mathbb{P})$ spazio di probabilità. Dagli assiomi I-II-III ricaviamo:

- $\mathbb{P}(\emptyset) = 0$
- **Addittività finita:** se A e B sono disgiunti allora

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

- $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$
- **Monotonia:** se $A \subset B$, allora $\mathbb{P}(A) \leq \mathbb{P}(B)$

Dimostrazione: 1 - Spazi di probabilità.pdf, pagina 12.

Teorema: Consideriamo un esperimento aleatorio descritto da uno spazio campionario finito

$$\Omega = \{\omega_1, \dots, \omega_N\}$$

con esiti equiprobabili

$$\mathbb{P}(\{\omega_1\}) = \dots = \mathbb{P}(\{\omega_N\})$$

In tal caso diciamo che $\mathbb{P}$ è la **probabilità uniforme** e valgono le seguenti proprietà:

- dato un qualunque elemento elementare vale

$$\mathbb{P}(\{\omega_i\}) = \frac{1}{N}$$

- dato un qualunque evento A vale la **formula di Laplace**

$$\mathbb{P}(A) = \frac{n \text{ di eventi elementari che compongono } A}{N} = \frac{|A|}{|\Omega|} = \frac{\text{casi favorevoli}}{\text{casi contrari}}$$

Dimostrazione: 1 - Spazi di probabilità.pdf, pagina 16.

Ora possiamo svolgere problemi di calcolo combinatorio!

Teorema: Formula dell'unione di due eventi, Siano A e B due eventi qualunque (non necessariamente disgiunti) allora

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

2 Probabilità codizionata e indipidenza

Consideriamo l'evento A e indichiamo $\mathbb{P}(A)$ la sua probabilità. Veniamo a sapere con un altro evento B avvenga, come calcoliamo la nuova probabilità che tenga conto?

$$\mathbb{P}(A|B)$$

La chiamiamo **probabilità condizionata** di A dato B .

Definizione: La probabilità condizionata di A dato B è

$$\mathbb{P} = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

A parole possiamo dire

$$\mathbb{P}(A|B) = \frac{\text{probabilità de casi veri favorevoli}}{\text{probabilità de casi veri possibili}}$$

Non vale quasi mai l'uguaglianza

$$\mathbb{P}(A|B) \neq \mathbb{P}(B|A)$$

Analizziamo ora dei casi un po particolari:

- Caso $B = \Omega$:

$$\mathbb{P}(A|\Omega) = \frac{\mathbb{P}(A \cap \Omega)}{\mathbb{P}(\Omega)} = \mathbb{P}(A)$$

- Caso $A = \Omega$:

$$\mathbb{P}(\Omega|B) = \frac{\mathbb{P}(\Omega \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1$$

- Caso $B \subset A$:

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1$$

Teorema: Sia B un evento t.c. $\mathbb{P} > 0$. Allora valgono:

- (Assioma I) Per ciascun evento (sottoinsieme) A di Ω , vale

$$0 \leq \mathbb{P}(A|B) \leq 1$$

- $\mathbb{P}(\Omega|B) = 1$

- (Assioma III) Vale la proprietà di **addittività numerabile**. Sia $A_1, \dots, A_{infy}$ successione di eventi disgiunti e sia

$$A = \bigcup_{n=1}^{\infty} A_n$$

Allora vale

$$\mathbb{P}(A|B) = \sum_{n=1}^{\infty} \mathbb{P}(A_n|B)$$

- $\mathbb{P}(\emptyset|B) = 0$
- **addittività finita:** se A_1 e A_2 sono disgiunti allora

$$\mathbb{P}(A_1 \cup A_2|B) = \mathbb{P}(A_1|B) + \mathbb{P}(A_2|B)$$

- $\mathbb{P}(A^c|B) = 1 - \mathbb{P}(A|B)$
- **Monotonia:** se $A_1 \subset A_2$, allora

$$\mathbb{P}(A_1|B) \leq \mathbb{P}(A_2|B)$$

Dimostrazione: 2 - Probabilità condizionata e indipendenza.pdf, pagina 5.

Notiamo come la stessa probabilità condizionata sia anch'essa una probabilità

$$\mathbb{P}(\cdot|B) : \mathcal{P}(\Omega) \rightarrow [0, 1]$$

2.1 Regola della catena

Utilizzo della probabilità condizionata:

Alcune volte si utilizza la **regola della catena** (*formula della probabilità composta*)

$$\mathbb{P}(A \cap B) = \mathbb{P}(A|B)\mathbb{P}(B)$$

con $\mathbb{P}(A|B)$ e $\mathbb{P}(A)$ noti.

Teorema: Siano A e B due eventi, $\mathbb{P}(B) > 0$. Vale la regola della catena:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A|B)\mathbb{P}(B)$$

In generale (con $\mathbb{P}(A_1 \cap \dots \cap A_{n-1}) > 0$)

$$\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1}) \mathbb{P}(A_1)$$

Da qui ricaviamo che

$$A_1 \cap \dots \cap A_{n-1} \subset A_1 \cap \dots \cap A_{n-2} \subset \dots \subset A_1$$

Dimostrazione: 2 - Probabilità condizionata e indipendenza.pdf, pagina 6.

Definizione: Si dice che n eventi $B_1, \dots, B_n$ sono una **partizione** di Ω se:

- $B_1, \dots, B_n$ sono disgiunti
- l'unione di $B_1, \dots, B_n$ è Ω

$$\Omega = \bigcup_{i=1}^n B_i$$

2.2 Eventi indipendenti

Un evento indipendente lo possiamo definire quando

$$\mathbb{P}(A|B) = \mathbb{P}(A)$$

Ovvero che la probabilità che si verifichi A con o senza B è la stessa.

Definizione: Due eventi A e B si dicono **indipendenti** se

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$$

Scriveremo quindi

$$A \perp\!\!\!\perp B$$

La proprietà di essere indipendenti è ovviamente simmetrica.

Vediamo la simmetria:

- Se $\mathbb{P}(B) > 0$ allora

$$A \perp\!\!\!\perp B \iff \mathbb{P}(A|B) = \mathbb{P}(A)$$

- Se $\mathbb{P}(A) > 0$ allora

$$A \perp\!\!\!\perp B \iff \mathbb{P}(B|A) = \mathbb{P}(B)$$

Quindi se $\mathbb{P}(A) > 0$ e $\mathbb{P}(B) > 0$ allora le seguenti cose sono equivalenti:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B), \quad \mathbb{P}(A|B) = \mathbb{P}, \quad \mathbb{P}(B|A) = \mathbb{P}(B)$$

Dimostrazione: 2 - Probabilità condizionata e indipendenza.pdf, pagina 13.

Teorema: Siano A e B due eventi indipendenti. Allora anche A^c e B oppure A e B^c sono indipendenti.

Dimostrazione: 2 - Probabilità condizionata e indipendenza.pdf, pagina 13.

Definizione: Tre eventi A, B, C si dicono **indipendenti** se valgono simultaneamente:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$$

$$\mathbb{P}(A \cap C) = \mathbb{P}(A)\mathbb{P}(C)$$

$$\mathbb{P}(B \cap C) = \mathbb{P}(B)\mathbb{P}(C)$$

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C)$$

2.3 Formula delle probabilità totali

Teorema della formula delle probabilità totali: Sia $B_1, \dots, B_n$ una partizione di Ω allora per ogni evento A vale

$$\underbrace{\mathbb{P}(A)}_{\text{prob. totale di } A} = \sum_{i=1}^n \underbrace{\mathbb{P}(A \cap B_i)}_{\text{prob. parziale di } A}$$

Se inoltre si ha che $\mathbb{P}(B_i) > 0$ per ogni $i = 1, \dots, n$ allora vale

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A|B_i)\mathbb{P}(B_i)$$

Dimostrazione: 2 - Probabilità condizionata e indipendenza.pdf, pagina 18.

2.4 Formula di Bayes

Teorema della formula di Bayes: Siano A e B due eventi t.c. $\mathbb{P}(A) > 0$, $\mathbb{P}(B) > 0$ allora vale

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A|B)\mathbb{P}(B)}{\mathbb{P}(A)}$$

Dimostrazione: 2 - Probabilità condizionata e indipendenza.pdf, pagina 21.

Molto spesso la utilizziamo insieme alla formula delle probabilità totali:

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A|B)\mathbb{P}(B)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A|B)\mathbb{P}(B)}{\sum_{i=1}^n \mathbb{P}(A|B_i)\mathbb{P}(B_i)}$$

3 Calcolo combinatorio

Abbiamo detto che dato Ω finito ed esiti equiprobabili allora

$$\Omega = \{\omega_1, \dots, \omega_N\}$$
$$\mathbb{P}(\{w_i\}) = \frac{1}{N}$$

e che dato un qualsiasi evento A vale la formula di Laplace

$$\mathbb{P}(A) = \frac{n \text{ di eventi elementari che compongono } A}{N} = \frac{|A|}{|\Omega|} = \frac{\text{casi favorevoli}}{\text{casi contrari}}$$

Studieremo ora il calcolo combinatorio che è lo strumento per svolgere questi calcoli anche quando tali numeri sono particolarmente elevati.

3.1 Cardinalità e corrispondenza biunivoca

Possiamo scrivere Laplace come

$$\mathbb{P} = \frac{|A|}{|\Omega|}$$

Definizione: due insiemi A e B si dice A è in corrispondenza biunivoca con B se esiste una funzione biettiva (iniettiva e suriettiva)

$$f : A \rightarrow B$$

ovvero

$$|A| = |B| \iff A \text{ e } B \text{ sono in corrispondenza biunivoca}$$

3.2 Fattoriale e coefficiente binomiale

Ricordiamo che il *coefficiente binomiale* è

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} \text{ con } k \leq n$$
$$= \binom{n}{n-k}$$

e anche

$$\binom{n}{0} = \binom{n}{n} = 1$$
$$\binom{n}{1} = 1$$

Per $k < n$ vale la formula di *Stifel*

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$$

Infine vale anche la formula di *Netwon* con $a, b \in \mathbb{R}$

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$$

3.3 Metodo delle scelte successive

Permette di determinare la cardinalità di un insieme una volta caratterizzati univocamente i suoi elementi tramite un numero finito di scelte successive.

Metodo delle scelte successive: Supponiamo che **ciasun** elemento di un insieme A possa essere determinato tramite **una e una sola** sequenza di k scelte successive, in cui ogni scelta viene effettuata tra un numero fissato di possibilità (tale numero di possibilità, qui di seguito indicato con $n_1, \dots, n_k$ non dipende dalle scelte precedenti ma solo da k):

- la prima scelta viene effettuata tra n_1 possibilità
- la seconda scelta viene effettuata tra n_2 possibilità
- ...
- a k -esima scelta viene effettuata tra n_k possibilità

Allora la cardinalità di A è

$$|A| = n_1 \cdot n_2 \cdot \dots \cdot n_k$$

3.4 Disposizioni e combinazioni

Definizione disposizioni con ripetizione: Dato insieme E , $|E| = n$ e $k \in \mathbb{N}$. Indichiamo con $DR_{n,k}$, insieme delle disposizioni con k elementi di E , ossia l'insieme di tutte le sequenze ordinate di k di E non necessariamente distinti

$$DR_{n,k} = \{(x_1, \dots, x_k) : x_i \in E\} = \underbrace{E \times \dots \times E}_{k \text{ volte}}$$
$$|DR_{n,k}| = n^k$$

Possiamo notare come $DR_{n,k}$ esprime i modi in cui possiamo disporre in maniera ordinata e ripetuta un numero k di oggetti scelti da un insieme di n oggetti.

Definizione disposizioni semplici: Dato E insieme e $|E| = n$ e $k \leq n$. Indichiamo con $D_{n,k}$ l'insieme delle disposizioni semplici di k elementi di E , ovvero l'insieme che comprende tutte le sequenze ordinate di k elementi distinti di E

$$D_{n,k} = \{(x_1, \dots, x_k) : x_i \in E \text{ distinti}\}$$
$$|D_{n,k}| = n(n-1) \dots (n-k+1) = \frac{n!}{(n-k)!}$$

Possiamo notare come $D_{n,k}$ esprime i modi in cui possiamo disporre, in maniera ordinata e non ripetuta, un numero k di oggetti scelti da un insieme di n oggetti.

Definizione permutazioni: Sia E insieme, $|E| = n$. Indichiamo con P_n l'insieme delle permutazioni degli n elementi di E , ossia l'insieme $D_{n,n}$

$$|P_n| = |D_{n,n}| = n!$$

Possiamo notare come P_n esprime i modi in cui possiamo disporre, in maniera ordinata e non ripetuta, n oggetti.

Definizione combinazione: Dato E insieme, $|E| = n$ e $k \leq n$. Indichiamo con $C_{n,k}$ l'insieme delle combinazioni (semplici o senza ripetizioni) di k elementi di E , ossia la famiglia dei sottoinsiemi di E di cardinalità k

$$C_{n,k} = \{A \subset E : |A| = k\}$$
$$|C_{n,k}| = \binom{n}{k}$$

Vale anche la seguente equivalenza

$$\frac{n!}{(n-k)!} = |C_{n,k}| k!$$
$$|D_{n,k}| = |C_{n,k}| |P_k|$$

ORDINE \ RIPETIZIONE	<i>Senza</i> ripetizione	<i>Con</i> ripetizione
	<i>Estrazione senza reimmissione</i>	<i>Estrazione con reimmissione</i>
Si tiene conto dell'ordine	$\Omega = \mathbf{D}_{n,k}$ $ \Omega = \frac{n!}{(n-k)!}$	$\Omega = \mathbf{DR}_{n,k}$ $ \Omega = n^k$
Non si tiene conto dell'ordine	<i>Estrazione simultanea</i> $\Omega = \mathbf{C}_{n,k}$ $ \Omega = \frac{ \mathbf{D}_{n,k} }{k!} = \binom{n}{k}$	—

$$\frac{\text{casi favorevoli in } C_{n,k}}{\text{casi possibili in } C_{n,k}} = \frac{k!(\text{casi favorevoli in } C_{n,k})}{k!(\text{casi possibili in } C_{n,k})} = \frac{\text{casi favorevoli in } D_{n,k}}{\text{casi possibili in } D_{n,k}}$$

3.5 Variabili aleatorie

Definizione: Un evento è una affermazione riguardante l'ipotetico risultato dell'esperimento aleatorio, di cui è possibile dire con certezza se è vera oppure falsa una volta noto l'esito dell'esperimento aleatorio.

Definizione: Ogni evento è rappresentato dal sottoinsieme di Ω costituito dai casi favorevoli. Un qualunque sottoinsieme di Ω lo chiamiamo ancora evento.

Definizione: Una **variabile aleatoria** è una affermazione riguardante l'ipotetico risultato dell'esperimento aleatorio. Tale affermazione identifica uno e un solo numero reale una volta noto l'esito dell'esperimento aleatorio.

In altre parole, mentre per un evento ha senso domandarsi "*è vero oppure no?*", per una variabile aleatoria ha senso chiedersi "*quanto vale?*".

Una variabile aleatoria viene indicata con una lettera maiuscola.

Definizione: Ogni variabile aleatoria è rappresentata dalla funzione Ω in $\mathbb{R}$ il cui valore numerico in corrispondenza di un qualunque esito dell'esperimento aleatorio, coincide con quanto fornito dall'affermazione.

Una qualunque funzione da Ω in $\mathbb{R}$ la chiameremo **variabili aleatoria**.

Il termine *variabile aleatoria* indica sia l'affermazione che la funzione.

3.5.1 Distribuzione di una variabile aleatoria

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilità e $X : \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. Si dice che $E \subset \Omega$ è un evento associato ad X se esiste un sottoinsieme di B dell'insieme dei numeri reali $\mathbb{R}$ t.c.

$$E = \{\omega \in \Omega : X(\omega) \in B\}$$

= "sottoinsieme di Ω costituito da tutti e soli gli esiti ω per cui $X(\omega) \in B$ ".

Viceversa, dato un qualunque $B \subset \mathbb{R}$ il sottoinsieme di Ω dato da

$$\{\omega \in \Omega : X(\omega) \in B\}$$

si chiama **evento associato ad X** .

Per brevità indicheremo il sottoinsieme

$$\{\omega \in \Omega : X(\omega) \in B\}$$

nel modo seguente

$$\{X \in B\} \text{ oppure } (X \in B)$$

Ad ogni variabile aleatoria X è associato un oggetto di fondamentale importanza, la distribuzione o legge di X , che verrà indicata con $\mathbb{P}_X$. Essa è una probabilità su $\mathbb{R}$.

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilità e $X : \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. Si chiama **distribuzione** di X la probabilità

$$\mathbb{P}_X : \mathcal{P}(\mathbb{R}) \rightarrow [0, 1]$$

definita da

$$\mathbb{P}_X(B) = \mathbb{P}(X \in B), \quad \forall B \subset \mathbb{R}$$

Per dire che X ha distribuzione $\mathbb{P}_X$ scriveremo

$$X \sim \mathbb{P}_X$$

Variabili aleatorie costanti de delta di Dirac Sia X la variabile aleatoria costante da

$$X(\omega) = a, \quad \forall \omega \in \Omega$$

dove a è un numero reale fissato. Possiamo calcolare esplicitamente la distribuzione di X per ogni $B \subset \mathbb{R}$

$$\mathbb{P}_X(B) = \mathbb{P}(X \in B) = \begin{cases} \mathbb{P}(\Omega), & \text{se } a \in B \\ \mathbb{P}(\emptyset), & \text{se } a \notin B \end{cases} = \begin{cases} 1, & \text{se } a \in B \\ 0, & \text{se } a \notin B \end{cases}$$

Notiamo che $\mathbb{P}_X$ coincide con δ_a (delta di Dirac in a).

Variabili aleatorie indicatrici Siano A un evento e $X = 1_A$, la variabile aleatoria indicatrice relativa all'evento A . Anche in questo caso possiamo calcolare in maniera esplicita la distribuzione di X . Infatti per ogni $B \subset \mathbb{R}$

$$\{X \in B\} = \begin{cases} A, & \text{se } 1 \in B \text{ e } 0 \notin B \\ A^c, & \text{se } 1 \notin B \text{ e } 0 \in B \\ \Omega, & \text{se } 1 \notin B \text{ e } 0 \in B \\ \emptyset, & \text{se } 1 \in B \text{ e } 0 \notin B \end{cases}$$

Quindi

$$\mathbb{P}_X(B) = \begin{cases} \mathbb{P}(A), & \text{se } 1 \in B \text{ e } 0 \notin B \\ 1 - \mathbb{P}(A), & \text{se } 1 \notin B \text{ e } 0 \in B \\ 1, & \text{se } 1 \notin B \text{ e } 0 \in B \\ 0, & \text{se } 1 \in B \text{ e } 0 \notin B \end{cases}$$

In altri termini si ha che $\mathbb{P}_X$ coincide con la seguente combinazione convessa di δ_0 e δ_1 : $(1 - \mathbb{P}(A))\delta_0 + \mathbb{P}(A)\delta_1$. Quindi

$$X \sim (1 - \mathbb{P}(A))\delta_0 + \mathbb{P}(A)\delta_1$$

Infatti per ogni $B \subset \mathbb{R}$

$$(1 - \mathbb{P}(A))\delta_0 + \mathbb{P}(A)\delta_1 = \begin{cases} \mathbb{P}(A), & \text{se } 1 \in B \text{ e } 0 \notin B \\ 1 - \mathbb{P}(A), & \text{se } 1 \notin B \text{ e } 0 \in B \\ 1, & \text{se } 1 \notin B \text{ e } 0 \in B \\ 0, & \text{se } 1 \in B \text{ e } 0 \notin B \end{cases}$$

Questo dimostra che $\mathbb{P}_X = (1 - \mathbb{P}(A))\delta_0 + \mathbb{P}(A)\delta_1$. Tale probabilità si chiama *distribuzione di Bernoulli di parametro $\mathbb{P}(A)$* .

3.5.2 Funzione di ripartizione (CDF)

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilità aleatoria. Si chiama **funzione di ripartizione CDF** di X la funzione

$$F_X : \mathbb{R} \rightarrow [0, 1]$$

definita da

$$F_X(x) = \mathbb{P}(X \leq x) = \mathbb{P}_X((-\infty, x]), \quad \forall x \in \mathbb{R}$$

Per dire che X ha funzione di ripartizione F_X scriveremo

$$X \sim F_X$$

Variabili aleatorie costanti Sia a un numero reale e X la variabile aleatoria costante e uguale ad a . Allora

$$F_X(x) = \begin{cases} 0, & \text{se } x < a \\ 1, & \text{se } x \geq a \end{cases}$$

Variabili aleatorie indicatrici Sia A un evento e $X = 1_A$. Allora

$$F_X(x) = \begin{cases} 0, & x < 0 \\ 1 - \mathbb{P}(A), & 0 \leq x < 1 \\ 1, & x \geq 1 \end{cases}$$

Teorema: Sia $(\Omega, \mathbb{R})$ uno spazio di probabilità e $X : \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. La funzione di ripartizione F_X di X verifica le seguenti proprietà:

- F_X è monotona crescente (non necessariamente strettamente)
- F_X è continua a destra: $\lim_{y \rightarrow x+} F_X(y) = F_X(x) \quad \forall x \in \mathbb{R}$
- $\lim_{x \rightarrow -\infty} F_X(x) = 0$
- $\lim_{x \rightarrow +\infty} F_X(x) = 1$

Viceversa se la funzione $G : \mathbb{R} \rightarrow [0, 1]$ verifica tutte le proprietà, allora esistono uno spazio di probabilità $(\Omega, \mathbb{P})$ ed una variabile aleatoria X t.c. $G = F_X$.

Dimostrazione: 3.5 - Variabili aleatorie.pdf, pagina 12.

Lemma: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilità. Allora $\mathbb{P}$ verifica le seguenti proprietà di stabilità per i limiti monotoni:

- siano $(A_n)_n$ una successione di eventi con $A_n \subset A_{n+1}$ e $A = \bigcup_n A_n$, allora vale che

$$\lim_{n \rightarrow +\infty} \mathbb{P}(A_n) = \mathbb{P}(A)$$

- siano $(A_n)_n$ una successione di eventi con $A_n \supset A_{n+1}$ e $A = \bigcap_n A_n$, allora vale che

$$\lim_{n \rightarrow +\infty} \mathbb{P}(A_n) = \mathbb{P}(A)$$

Dimostrazione: 3.5 - Variabili aleatorie.pdf, pagina 11.

Teorema probabilità di intervalli in termini di F_X : Valgono le seguenti uguaglianze

$$\begin{aligned} \mathbb{P}(X = x) &= F_X(x) - F_X(x-) \\ \mathbb{P}(x < X \leq y) &= F_X(y) - F_X(x) \\ \mathbb{P}(x \leq X \leq y) &= F_X(y) - F_X(x-) \\ \mathbb{P}(x \leq X < y) &= F_X(y-) - F_X(x-) \\ \mathbb{P}(x < X < y) &= F_X(y-) - F_X(x) \end{aligned}$$

4 Variabili aleatorie discrete

La *non definizione* dice: una variabile aleatoria si dice **discreta** se assume un numero finito (o al più un'infinita numerabile) di valori.

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilità e X una variabile aleatoria. La funzione $p_X : \mathbb{R} \rightarrow [0, 1]$ data da

$$p_X(x) = \mathbb{P}(X = x), \quad \forall x \in \mathbb{R}$$

si chiama **densità discreta** o **funzione di massa di probabilità** (PMF) di X .

Si noti che $p_X(x)$ è la probabilità che la variabile aleatoria X assuma il valore x . Per tale ragione, $p_X(x)$ verifica necessariamente le disuguaglianze:

$$0 \leq p_X(x) \leq 1, \quad \forall x \in \mathbb{R}$$

La definizione di variabile aleatoria discreta fa intervenire la funzione p_X .

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilità e X una variabile aleatoria. Si dice che X è una **variabile aleatoria discreta** (in breve v.a.d.) se esiste un sottoinsieme $\mathcal{S}_X$ di $\mathbb{R}$, finito o al più infinito numerabile, quindi

$$\mathcal{S}_X = \{x_1, \dots, x_n\} \text{ oppure } \mathcal{S}_X = \{x_1, \dots, x_i, \dots\}$$

tale che:

- $p_X(x_i) > 0 \forall x_i \in \mathcal{S}$ (*minimalità* di $\mathcal{S}_X$)
- $\mathbb{P}(X \in \mathcal{S}_X) = \sum_i p_X(x_i) = 1$

L'insieme $\mathcal{S}_X$ si chiama **supporto** di X .

Tabella della densità discreta Nel caso in cui $\mathcal{S}_X$ sia un insieme finito, quindi $\mathcal{S}_X = \{x_1, \dots, x_n\}$

X	x_1	x_2	$\dots$	x_n
p_X	$p_X(x_1)$	$p_X(x_2)$	$\dots$	$p_X(x_n)$

Variabili aleatorie costanti Sia a un numero reale e X la variabile aleatoria costante uguale ad a . Allora X è una variabile aleatoria discreta con supporto $\mathcal{S}_X = \{a\}$ e densità discreta.

X	a
p_X	1

Variabili aleatorie indicatrici Sia A un evento e $X = 1_A$ la variabile aleatoria indicatrice relativa all'evento A . Allora X è una variabile aleatoria discreta con supporto $\mathcal{S}_X = \{0, 1\}$ e densità discreta

X	0	1
p_X	$1 - \mathbb{P}(A)$	$\mathbb{P}(A)$

4.1 Caratterizzazione delle variabili aleatorie discrete

Teorema: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilità e X una variabile aleatoria. Le seguenti affermazioni sono equivalenti:

- X è una variabile aleatoria discreta
- F_X è una funzione costante a tratti

$$\begin{aligned}F_X(x_i) - F_X(x_i-) &= p_X(x_i) \\ F_X(x) &= \sum_{x_i \leq x} p_X(x_i) \quad \forall x \in \mathbb{R}\end{aligned}$$

- $\mathbb{P}_X$ la distribuzione di X è concentrata nei punti $x_1, x_2, \dots$ di $\mathcal{S}_X$

$$\mathbb{P}_X = \sum_i p_X(x_i) \delta_{x_i}$$

Infine vale la formula

$$\mathbb{P}(X \in B) = \sum_{x_i \in B} p_X(x_i) \quad \forall B \subset \mathbb{R}$$

4.2 Indici di sintesi di una distribuzione: μ e σ^2

La distribuzione o legge di una variabile aleatoria può essere descritta in maniera sintetica tramite due quantità numeriche, la **media** (o valore atteso) e la varianza.

La media è un indice di posizione, ovvero indica qual è il valore “centrale” della distribuzione.

$$\mu_{\text{artim}} = \frac{x_1 + \dots + x_n}{n}$$

Questa è una *media pesata*, ovvero tutti gli x_i hanno lo stesso peso $\frac{1}{n}$.

La **varianza** è un indice di dispersione, ossia dice quanto la distribuzione si concentra attorno alla media.

$$\begin{aligned}\frac{(x_1 - \mu)^2 + \dots + (x_n - \mu)^2}{n} \\ = \frac{1}{n} \|x - \mu 1\|^2\end{aligned}$$

4.2.1 Media o valore atteso

Definizione: Sia x una variabile aleatoria discreta con supporto $\mathcal{S}_X = \{x_1, x_2, \dots\}$. La media (o valore atteso) di X è data da:

$$\mathbb{E}[X] = \sum_i x_i p_X(x_i)$$

La media la indichiamo con μ oppure μ_X .

Il simbolo $\mathbb{E}$ significa *expected value* (valore atteso).

Teorema: Sia X una variabile aleatoria discreta con densita' p_X e supporto $\mathcal{S}_X = \{x_1, x_2, \dots\}$. Inoltre siano $h : \mathbb{R} \rightarrow \mathbb{R}$ e $Y = h(X)$. Allora

$$\mathbb{E}[Y] = \mathbb{E}[h(X)] = \sum_i h(x_i) p_X(x_i)$$

Teorema Linearita' del valore atteso: Sia X una variabile aleatoria discreta. Inoltre siano $h : \mathbb{R} \rightarrow \mathbb{R}$, $g : \mathbb{R} \rightarrow \mathbb{R}$ e $a, b \in \mathbb{R}$ costanti. Allora

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$$

In generale:

$$\mathbb{E}[ah(X) + bg(X)] = a\mathbb{E}[h(X)] + b\mathbb{E}[g(X)]$$

4.2.2 Varianza

Definizione: Sia X una variabile aleatoria discreta con densita' discreta p_X e supporto $\mathcal{S}_X = \{x_1, x_2, \dots\}$. La varianza di X e' data da:

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_i (x_i - \mathbb{E}[X])^2 p_X(x_i)$$

La varianza si indica con σ^2 oppure σ_X^2 .

La radice quadrata della varianza si chiama **deviazione standard** (o scarto quadratico medio o anche scostamento quadratico medio) e si indica con σ oppure σ_X .

Teorema: Sia X una variabile aleatoria discreta con densita' discreta p_X e supporto $\mathcal{S}_X = \{x_1, x_2, \dots\}$. Vale che

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \sum_i x_i^2 p_X(x_i) - \mathbb{E}[X]^2$$

Teorema Proprieta' della varianza: Siano X una variabile aleatoria discreta e $a, b \in \mathbb{R}$ costanti. Allora

- $\text{Var}(X) \geq 0$
- $\text{Var}(b) = 0$ e viceversa: se $\text{Var}(X) = 0$ allora X e' una variabile aleatoria costante
- $\text{Var}(aX + b) = a^2 \text{Var}(X)$

4.3 Distribuzioni discrete notevoli

In questa sezione vediamo le principali distribuzioni discrete.

Distribuzione uniforme discreta Sia $\{x_1, \dots, x_n\}$ un sottoinsieme finito di $\mathbb{R}$. Diciamo che X ha distribuzione uniforme discreta sull'insieme $\{x_1, \dots, x_n\}$ se X e' una variabile aleatoria

discreta con $\mathcal{S}_X = \{x_1, \dots, x_n\}$ e densita' discreta data da

$$\begin{array}{c|c|c|c|c} X & x_1 & x_2 & \dots & x_n \\ \hline p_X & \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{array}$$

In tal caso scriviamo

$$X \sim \text{Unif}(\{x_1, \dots, x_n\})$$

Si noti che

$$\begin{aligned} \mathbb{E}[X] &= \mu_{\text{aritm}} = \frac{x_1 + \dots + x_n}{n} \\ \text{Var}(X) &= \frac{(x_1 - \mathbb{E}[X])^2 + \dots + (x_n - \mathbb{E}[X])^2}{n} \end{aligned}$$

Distribuzione di Bernoulli Sia $0 \leq p \leq 1$. Diciamo che X ha **distribuzione di Bernoulli** (o bernoulliana) di parametro p se X e' una variabile aleatoria discreta con $\mathcal{S}_X = \{0, 1\}$ e densita' discreta data da

$$\begin{array}{c|c|c} X & 0 & 1 \\ \hline p_X & 1-p & p \end{array}$$

In tal caso scriveremo

$$X \sim B(p)$$

Le variabili aleatorie di Bernoulli sono tutte e sole variabili aleatorie indicatrici. Infatti:

$$X = 1_A, \quad \text{con } A = \{X = 1\}$$

Si noti che

$$\begin{aligned} \mathbb{E}[X] &= p \\ \text{Var}(X) &= p(1-p) \end{aligned}$$

Distribuzione binomiale Consideriamo ora una generalizzazione della distribuzione bernoulliana: la *distribuzione binomiale*.

Immaginiamo ora di ripetere n volte l'esperimento aleatorio a cui l'evento A si riferisce, in modo tale che i vari esperimenti siano tra loro "indipendenti". Per ciascun esperimento consideriamo la corrispondente v.a. bernoulliana. Abbiamo dunque n variabili aleatorie bernoulliane:

$$X_1 \sim B(p), \quad X_2 \sim B(p), \quad \dots, \quad X_n \sim B(p)$$

Consideriamo la seguente variabile aleatoria

$$X = \text{"n. di successi negli } n \text{ esperimenti"}$$

dove "*successo*" si intende che l'evento A si sia verificato.

Quindi X e' il numero di volte che A si e' verificato negli n esperimenti. Notiamo che:

$$X = X_1 + \dots + X_n$$

Proposizione: Siano $0 \leq p \leq 1, n \in \mathbb{N}$ e $X \sim B(n, p)$. Allora

$$\begin{aligned} \mathbb{E}[X] &= np \\ \text{Var}(X) &= np(1-p) \end{aligned}$$

Distribuzione di Poisson La distribuzione di Poisson che ora introduciamo e' un "caso limite" della distribuzione binomiale, che si ottiene a partire dalla distribuzione binomiale quando

$$n \rightarrow +\infty, \quad p \rightarrow 0, \quad np \rightarrow \lambda$$

dove $\lambda > 0$ e' un costante fissata.

Anche se in modo impreciso, possiamo dire piu' semplicemente che se $X \sim B(n, p)$, n e' "molto grande" e p e' "molto piccolo", allora X ha approssimativamente distribuzione di Poisson di parametro $\lambda = np$.

Diciamo che X ha distribuzione di Poisson di parametro λ se X e' un variabile aleatoria discreta con $\mathcal{S}_X = \{0, 1, 2, \dots\}$ e densita' discreta data da

$$p_X(k) = \mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!} \quad \forall k = 0, 1, 2, \dots$$

In tal caso scriviamo

$$X \sim \text{Poisson}(\lambda)$$

Si ricprdi che

$$\sum_{k=0}^{+\infty} \frac{x^k}{k!} = e^x$$

Quindi si verifica che

$$\sum_{k=0}^{+\infty} p_X(k) = \sum_{k=0}^{+\infty} \frac{x^k}{k!} = 1$$

Proposizione Siano $\lambda > 0$ e $X \sim \text{Poisson}(\lambda)$. Allora

$$\begin{aligned} \mathbb{E}[X] &= \lambda \\ \text{Var}(X) &= \lambda \end{aligned}$$

5 Variabili aleatorie continue

Se dobbiamo definire per esempio la vita di un componente X diremo che la sua vita e' maggiore uguale ad zero, ovvero $\mathcal{S}_X = \{0, +\infty\}$.

Innanzitutto, poiche' X puo' assumere un'infinita' continua di valori, l'eventualita' che ne assuma esattamente uno in particolare (ad esempio il numero $x = 3,45362$) e' praticamente impossibile.

$$\begin{aligned} p_X(x) &= \mathbb{P}(X = x) = 0 \quad \forall x \in \mathbb{R} \\ \mathbb{P}(a \leq X \leq b) &> 0 \quad \text{se } [a, b] \subset [0, +\infty] \end{aligned}$$

In altri termini, la densita' discreta p_X per una variabile aleatoria continua e' sempre identicamente uguale a zero, non gioca dunque alcun ruolo.

5.1 Definizioni di densità continua e v.a. continua

Definizione: Una funzione $f : \mathbb{R} \rightarrow \mathbb{R}$ si dice **densità** (continua) o **funzione di probabilità** (PDF) se:

- $f(x) \geq 0 \quad \forall x \in \mathbb{R}$
- $\int_{-\infty}^{+\infty} f(x)dx = 1$

Definizione Sia $(\Omega, \mathbb{P})$ uno spazio di probabilità e X una variabile aleatoria. Si dice che X è una variabile aleatoria continua (v.a.c) se esiste una densità continua indicata con f_X t.c:

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f_X(x)dx, \quad \forall [a, b] \subset \mathbb{R}$$

$$\mathbb{P}(X \in B) = \int_B f_X(x)dx, \quad \forall B \subset \mathbb{R}$$

Notiamo in particolare che la probabilità che una variabile aleatoria continua X assuma valori in un intervallo non dipende dal fatto che gli estremi dell'intervallo siano inclusi o esclusi, contrariamente a quanto accade per le variabili aleatorie discrete.

Teorema Sia X variabile aleatoria continua con densità f_X

- La densità discreta di X è identicamente uguale ad zero

$$p_X(x) = 0 \quad \forall x \in \mathbb{R}$$

- La funzione di ripartizione di X è data da

$$F_X(x) = \int_{-\infty}^x f_X(y)dy \quad \forall x \in \mathbb{R}$$

Possiamo dunque riassumere nel seguente schema le differenze principali tra variabili aleatorie discrete e continue:

VARIABILI ALEATORIE DISCRETE	VARIABILI ALEATORIE CONTINUE
densità discreta p_X	densità continua f_X
$\mathbb{P}(X \in B) = \sum_{x_i \in B} p_X(x_i)$	$\mathbb{P}(X \in B) = \int_B f_X(x) dx$
F_X è costante a tratti: $F_X(x) = \sum_{x_i \leq x} p_X(x_i)$	F_X è una funzione integrale o, equivalentemente, è una funzione assolutamente continua: $F_X(x) = \int_{-\infty}^x f_X(y) dy$

5.1.1 Dalla funzione di ripartizione alla densita' continua

Proposizione Sia X una variabile aleatoria e indichiamo con F_X la sua funzione di ripartizione. Supponiamo di sapere gia' che X e' una variabile aleatoria continua (quindi sappiamo gia' che F_X e' una funzione integrale). Allora, una densita' f_X e' data da

$$f_X(x) := F'_X(x) \quad \forall x \text{ in cui } F_X \text{ e' derivabile}$$

mentre, nei punti in cui F_X non e' derivabile, f_X pue' essere definita in modo arbitrario.

5.1.2 Funzioni di variabili aleatorie continue

Siano $h : \mathbb{R} \rightarrow \mathbb{R}$ una qualunque funzione e X una variabile aleatoria continua. Poniamo

$$Y = h(X)$$

Ricordiamo che quando X e' discreta, Y e' necessariamente anch'essa una variabile aleatoria discreta. Al contrario, quando X e' continua, non possiamo dire nulla su Y . In particolare, Y potrebbe essere discreta, continua, mista.

La situazione pie' semplice si ha quando la variabile aleatoria Y e' discreta. Si e' in tale situazione quando Y assume un numero finito o al pie' infinito numerabile di valori. Ad esempio, se $h(x) = 1_{x>10}$ allora:

$$Y = 1_{X>10} = \begin{cases} 1, & \text{se } X > 10 \\ 0, & \text{se } X \leq 10 \end{cases}$$

In tal caso Y e' discreta in quanto assume solo due valori: 0 e 1. In particolare, Y ha distribuzione di Bernoulli di parametro $p = \mathbb{P}(X > 10)$

$$Y \sim B(p)$$

5.2 Indici di sintesi di una distribuzione: μ e σ^2

Come per le variabili aleatorie discrete, definiamo valore atteso e varianza per variabili aleatorie continue.

5.2.1 Media o valore atteso

Definizione: Sia X una variabile aleatoria continua. La **media** (o valore atteso) di X e' data da

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) dx$$

La media si indicia anche con μ oppure μ_X .

Capitera' spesso di dover calcolare il valore atteso di una funzione di X :

$$Y = h(X)$$

Teorema: Sia X una variabile aleatoria continua. Inoltre, siano $h : \mathbb{R} \rightarrow \mathbb{R}$ e $Y = h(X)$. Allora:

$$\mathbb{E}[Y] = \mathbb{E}[h(X)] = \int_{-\infty}^{+\infty} h(x)f_X(x)dx$$

Ricordiamo infine la proprietà di linearità del valore atteso, già dimostrata nel caso discreto:

Teorema Linearità del valore atteso: Sia X una variabile aleatoria discreta. Inoltre siano $h : \mathbb{R} \rightarrow \mathbb{R}$, $g : \mathbb{R} \rightarrow \mathbb{R}$ e $a, b \in \mathbb{R}$ costanti. Allora

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$$

In generale:

$$\mathbb{E}[ah(X) + bg(X)] = a\mathbb{E}[h(X)] + b\mathbb{E}[g(X)]$$

5.2.2 Varianza

Definizione: Sia X una variabile aleatoria continua. La varianza di X è data da

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_{-\infty}^{+\infty} (x - \mathbb{E}[X])^2 f_X(x)dx$$

La varianza si indica anche con σ^2 oppure σ_X^2 .

La radice quadrata della varianza si chiama deviazione standard (o scarto quadratico medio o anche scostamento quadratico medio) e si indica con σ oppure σ_X .

Teorema: Sia X una variabile aleatoria continua. Vale che

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \int_{-\infty}^{+\infty} x^2 f_X(x)dx - \mathbb{E}[X]^2$$

Ricordiamo infine le seguenti proprietà, già dimostrate nel caso discreto:

Teorema Proprietà della varianza: Siano X una variabile aleatoria discreta e $a, b \in \mathbb{R}$ costanti. Allora

- $\text{Var}(X) > 0$
- $\text{Var}(b) = 0$ e viceversa: se $\text{Var}(X) = 0$ allora X è una variabile aleatoria costante
- $\text{Var}(aX + b) = a^2 \text{Var}(X)$

5.3 Distribuzioni continue notevoli

Distribuzione uniforme (continua) Diciamo che X ha **distribuzione uniforme (continua)** su (a, b) se X è una variabile aleatoria continua con densità

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{altrimenti} \end{cases}$$

In tal caso scriveremo

$$X \sim \text{Unif}(a, b)$$

Si noti che

$$F_X(x) = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x \geq b \end{cases}$$

Inoltre

$$\begin{aligned} \mathbb{E}[X] &= \int_a^b \frac{x}{b-a} dx = \frac{a+b}{2}, \\ \text{Var}(X) &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \int_a^b \frac{x^2}{b-a} dx - \left(\frac{a+b}{2}\right)^2 = \frac{(b-a)^2}{12} \end{aligned}$$

Distribuzione esponenziale Sia $\lambda > 0$. Diciamo che X ha **distribuzione esponenziale di parametro λ** se X e' una variabile aleatoria continua di densita'

$$f_X(x) = \begin{cases} 0, & x < 0 \\ \lambda e^{-\lambda x}, & x \geq 0 \end{cases}$$

In tal caso scriveremo

$$X \sim \text{Exp}(\lambda)$$

Si noti che

$$F_X(x) = \begin{cases} 0, & x \leq 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$

Inoltre

$$\begin{aligned} \mathbb{E}[X] &= \int_0^{+\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda} \\ \text{Var}(X) &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx - \frac{1}{\lambda^2} = \frac{1}{\lambda^2} \end{aligned}$$

La distribuzione esponenziale si usa ad esempio per descrivere il tempo di vita di un macchinario oppure di un componente.

Distribuzione normale (o gaussiana) Siano $\mu \in \mathbb{R}$ e $\sigma > 0$. Diciamo che X ha una **distribuzione normale (o gaussiana) di media μ e varianza σ^2** se X e' una variabile aleatoria continua con densita'

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\frac{(x-\mu)^2}{\sigma^2}}}, \quad \forall x \in \mathbb{R}$$

In tal caso scriviamo

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

Diciamo inoltre che X ha **distribuzione normale standard** se

$$X \sim \mathcal{N}(0, 1)$$

ovvero X ha distribuzione normale di media $\mu = 0$ e varianza $\sigma^2 = 1$. In tal caso la densita' di X e' data da

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}, \quad \forall x \in \mathbb{R}$$

Lemma (Integrale di Gauss): Vale che

$$\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}$$

Di conseguenza avremo che

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}, \quad \forall x \in \mathbb{R}$$
$$\int_{-\infty}^{+\infty} f_X(x) dx = 1$$

Proposizione: Siano $\mu \in \mathbb{R}, \sigma > 0$ e $X \in \mathcal{N}(\mu, \sigma^2)$

- $\mathbb{E}[X] = \mu$
- $\text{Var}(X) = \sigma^2$

La distribuzione normale standard ha un ruolo fondamentale nello studio della distribuzione normale. Cio' deriva dal fatto che qualunque variabile aleatoria normale diventa, eseguendo un riscalamento e una traslazione (in una parola, *standardizzando*), una variabile aleatoria normale standard.

Proposizione (Standardizzazione) Siano $\mu \in \mathbb{R}, \sigma > 0$ e $X \in \mathcal{N}(\mu, \sigma^2)$. Allora

$$Z = \frac{X - \mu}{\sigma}$$

Proposizione (Proprieta di Φ) Sia

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y^2} dy, \quad \forall x \in \mathbb{R}$$

La funzione di ripartizione di una variabile aleatoria normale standard. Φ verifica le seguenti proprieta'

- $\Phi(0) = \frac{1}{2}$
- $\Phi(-x) = 1 - \Phi(x), \quad \forall x \geq 0$

6 Vettori aleatori

6.1 Introduzione

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilit . Una qualunque funzione

$$(X, Y) : \Omega \rightarrow \mathbb{R}^2$$

si chiama **vettore aleatorio** (bidimensionale).
Piu' in generale, per qualunque funzione

$$(X_1, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n$$

si chiama **vettore aleatorio** (o **n-dimensionale**).

6.1.1 Distribuzione o legge di un vettore aleatorio

Come per le variabili aleatorie, possiamo associare ad ogni vettore aleatorio la sua distribuzione o legge. Diamo la definizione solo per il caso bidimensionale.

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilit  e $(X, Y) : \Omega \rightarrow \mathbb{R}^2$ un vettore aleatorio. Si chiama **distribuzione** o **legge** di (X, Y) la probabilit 

$$\mathbb{P}_{(X,Y)} : \mathcal{P}(\mathbb{R}^2) \rightarrow [0, 1] \quad (1)$$

definita da

$$\mathbb{P}_{(X,Y)}(B) = \mathbb{P}((X, Y) \in B), \quad \forall B \subset \mathbb{R}^2$$

Per dire che (X, Y) ha distribuzione o legge $\mathbb{P}_{(X,Y)}$ scriveremo

$$(X, Y) \sim \mathbb{P}_{(X,Y)}$$

Funzione di ripartizione congiunta.   possibile estendere al caso multidimensionale il concetto di funzione di ripartizione. Si pu  infatti definire la funzione di ripartizione congiunta di X e Y :

$$\begin{aligned} F_{(X,Y)}(x, y) &= P(\{X \leq x\} \cap \{Y \leq y\}) \\ &= P((X, Y) \in (-\infty, x] \times (-\infty, y]), \quad \forall (x, y) \in \mathbb{R}^2. \end{aligned}$$

dove la seconda uguaglianza discende dall'Osservazione 2 riportata sopra. Equivalentemente, possiamo definire $F_{(X,Y)}$ in termini della distribuzione di (X, Y) :

$$F_{(X,Y)}(x, y) = P_{(X,Y)}((-\infty, x] \times (-\infty, y]), \quad \forall (x, y) \in \mathbb{R}^2.$$

Nel caso multidimensionale, tuttavia, la funzione di ripartizione non   praticamente utilizzata. Infatti conviene lavorare direttamente con la densit  (discreta o continua).

6.1.2 Indipendenza di variabili aleatorie

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilit . Due variabili aleatorie X e Y si dicono **indipendenti** se

$$\mathbb{P}(X \in B_1, Y \in B_2) = \mathbb{P}(X \in B_1)\mathbb{P}(Y \in B_2)$$

per ogni $B_1, B_2 \subset \mathbb{R}$

$$\mathbb{P}_{(X,Y)}(B_1 \times B_2) = \mathbb{P}_X(B_1)\mathbb{P}_Y(B_2)$$

In tal caso scriviamo

$$X \perp Y$$

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilit , n variabili aleatorie $X_1, \dots, X_n$ si dicono **indipendenti** se

$$\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i)$$

per ogni $B_1, \dots, B_n \subset \mathbb{R}$.

Proposizione: Siano X e Y variabili aleatorie indipendenti. Siano inoltre $f : \mathbb{R} \rightarrow \mathbb{R}$ e $g : \mathbb{R} \rightarrow \mathbb{R}$ funzioni arbitrarie. Allora anche le variabili aleatorie

$$f(X) \quad \text{e} \quad g(Y)$$

sono **indipendenti**.

6.2 Vettori aleatori discreti

Definizione Sia $(\Omega, \mathbb{P})$ uno spazio di probabilit  e (X, Y) un vettore aleatorio. Si dice che (X, Y)   un vettore aleatorio discreto se sia X che Y sono variabili aleatorie discrete.

Definizione Sia $(\Omega, \mathbb{P})$ uno spazio di probabilit  e (X, Y) un vettore aleatorio. La funzione $p_{(X,Y)} : \mathbb{R}^2 \rightarrow [0, 1]$ data da

$$\begin{aligned} p_{(X,Y)} &= \mathbb{P}(X = x, Y = y) \\ &= \mathbb{P}((X, Y) = (x, y)), \quad \forall (x, y) \in \mathbb{R}^2 \end{aligned}$$

si chiama densit  discreta congiunta di X e Y .

Infine p_X e p_Y si chiamano **densit  discrete marginali** di X e Y , rispettivamente.

Teorema: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilit  e (X, Y) un vettore aleatorio discreto. Siano inoltre $\mathcal{S}_X$ e $\mathcal{S}_Y$ i supporti di X e Y rispettivamente. Valgono le seguenti propriet :

- $p_{(X,Y)}(x, y) = 0, \quad \forall (x, y) \notin \mathcal{S}_X \times \mathcal{S}_Y$
- $\sum_{x_i \in \mathcal{S}_X} \sum_{y_j \in \mathcal{S}_Y} p_{(X,Y)}(x_i, y_j) = 1$
- Vale la formula

$$\mathbb{P}((X, Y) \in B) = \sum_{(x_i, y_j) \in B} p_{(X,Y)}(x_i, y_j), \quad \forall B \subset \mathbb{R}^2$$

6.2.1 Densit  discreta congiunta e densit  discrete marginali

Teorema: Sia (X, Y) un vettore aleatorio discreto. Allora

$$p_X(x_i) = \sum_j p_{(X,Y)}(x_i, y_j), \quad \forall x_i \in \mathcal{S}_X$$

$$p_Y(y_j) = \sum_i p_{(X,Y)}(x_i, y_j), \quad \forall y_j \in \mathcal{S}_Y$$

Tabella della densit  discreta congiunta Nel caso in cui sia $\mathcal{S}_X$ che $\mathcal{S}_Y$ sono insiemi finiti, quindi

$$\mathcal{S}_X = \{x_1, \dots, x_n\}$$

$$\mathcal{S}_Y = \{y_1, \dots, y_m\}$$

possiamo riportare i valori di $p_{(X,Y)}$ in una tabella:

$X \backslash Y$	y_1	y_2	$\dots$	y_m	p_X
x_1	$p_{X,Y}(x_1, y_1)$	$p_{X,Y}(x_1, y_2)$	$\dots$	$p_{X,Y}(x_1, y_m)$	$p_X(x_1)$
x_2	$p_{X,Y}(x_2, y_1)$	$p_{X,Y}(x_2, y_2)$	$\dots$	$p_{X,Y}(x_2, y_m)$	$p_X(x_2)$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_n	$p_{X,Y}(x_n, y_1)$	$p_{X,Y}(x_n, y_2)$	$\dots$	$p_{X,Y}(x_n, y_m)$	$p_X(x_n)$
p_Y	$p_Y(y_1)$	$p_Y(y_2)$	$\dots$	$p_Y(y_m)$	1

6.2.2 Indipendenza e densit  discreta congiunta

Teorema Siano X e Y variabili aleatorie discrete. Allora X e Y sono indipendenti se e solo se

$$p_{(X,Y)}(x_i, y_j) = p_X(x_i)p_Y(y_j), \quad \forall (x_i, y_j) \in \mathcal{S}_X \times \mathcal{S}_Y$$

6.3 Valore atteso e varianza di una funzione di (X, Y)

Teorema Siano (X, Y) un vettore aleatorio discreto e $h : \mathbb{R}^2 \rightarrow \mathbb{R}$. Allora

$$\mathbb{E}[h(X, Y)] = \sum_{i,j} h(x_i, y_j) p_{(X,Y)}(x_i, y_j)$$

e

$$\text{Var}(h(X, Y)) = \mathbb{E}[(h(X, Y) - \mathbb{E}[h(X, Y)])^2] = \sum_{i,j} (h(x_i, y_j) - \mathbb{E}[h(X, Y)])^2 p_{(X,Y)}(x_i, y_j)$$

Vale inoltre la formula

$$\text{Var}(h(X, Y)) = \mathbb{E}[(h(X, Y))^2] - \mathbb{E}[h(X, Y)]^2 = \sum_{i,j} (h(x_i, y_j))^2 p_{(X,Y)}(x_i, y_j) - \mathbb{E}[h(X, Y)]^2$$

Corollario Siano X e Y variabili aleatorie discrete. Siano inoltre a e b due numeri reali fissati. Allora

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

Corollario Siano X e Y variabili aleatorie discrete. Se X e Y sono indipendenti allora

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$$

6.4 Indici di sintesi della distribuzione di un vettore aleatorio discreto

Definizione Siano X e Y variabili aleatorie discrete. La **covarianza** di X e Y e' data da

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \sum_{i,j} (x_i - \mathbb{E}[X])(y_j - \mathbb{E}[Y]) p_{(X,Y)}(x_i, y_j)$$

Se $\text{Cov}(X, Y) = 0$ le variabili aleatorie X e Y si dicono **scorrelate**.

Teorema Siano X e Y variabili aleatorie discrete. Vale che

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \sum_{i,j} x_i y_j p_{(X,Y)}(x_i, y_j) - \mathbb{E}[X]\mathbb{E}[Y]$$

Quindi se le variabili aleatorie X e Y sono indipendenti allora sono scorrelate.

Teorema Siano X e Y variabili aleatorie discrete. Vale che

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

Quindi se X e Y sono scorrelate vale che

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

6.5 Statistica descrittiva e teoremi limite

6.5.1 Statistica descrittiva

Branca della statistica che si occupa di descrivere e sintetizzare tramite indici, tabelle e grafici i dati in esame.

Una prima distinzione che e' necessario fare e' tra dati (o caratteri o variabili) quantitativi:

- I **dati quantitativi** sono dati numerici; essi si suddividono a loro volta in:
 - **discreti** se possono assumere solo un numero finito o al piu' un'infinita' numerabile di valori
 - **continui** se possono assumere un'infinita' continua di valori
- I **dati qualitativi** sono tutti gli altri dati

Ci sono meno strumenti a disposizione per trattare dati qualitativi. Inoltre, per riuscire a studiare dati qualitativi in maniera efficace e' utile che tali dati assumano un numero relativamente basso di valori tra loro distinti (come accade ad esempio nel caso in cui si studia il gruppo sanguigno di un insieme di persone oppure lo stato occupazionale dei laureati di un determinato corso di laurea).

6.5.2 Le frequenze: tabelle e grafici

La nozione forse piu' importante della Statistica descrittiva e' quella di **frequenza**, nelle sue varie forme. I valori di tali frequenze sono riportati innanzitutto in tabelle e poi rappresentati anche tramite opportuni grafici.

La frequenza (anche detta **frequenza assoluta**) di un determinato valore e' il numero di volte che quel valore e' stato osservato. A partire dalla frequenza assoluta si ricavano altri tipi di frequenze, in particolare:

- la **frequenza relativa**, data dal rapporto tra frequenza assoluta e numero totale di dati in esame
- la **frequenza percentuale**, che e' la frequenza relativa espressa in termini percentuali
- a **frequenza (percentuale) cumulata**, definita solo nel caso di dati quantitativi, la quale e' la somma delle frequenze percentuali dei valori minori o uguali a quello per cui la si sta calcolando. In modo analogo si definiscono la **frequenza assoluta cumulata** e la **frequenza relativa cumulata**.

6.5.2.1 Classi di frequenza

Nel caso di dati quantitativi giocano un ruolo importante le cosiddette **classi di frequenza**. Quest'ultime sono infatti necessarie nel caso di dati continui e utili nel caso di dati discreti che assumono un numero elevato di valori distinti. Le classi di frequenza sono **intervalli** contigui della retta reale. Stabilire quali debbano essere le classi da adottare non e' una scelta univoca, infatti il numero di classi e la loro ampiezza possono essere scelti in infiniti modi. Troppe classi rendono la tabella poco leggibile; troppo poche classi la rendono poco significativa: il numero giusto va scelto con buon senso. L'importante e' che *ogni dato appartenga ad una e una sola classe*.

Come si costruiscono le classi? Per semplicità noi considereremo solo il caso di classi aventi la stessa ampiezza (un'ampiezza differente può essere utile nel caso di dati con concentrazione molto variabile).

6.5.2.2 Indici

D'ora in avanti consideriamo solo dati (o variabili o caratteri) quantitativi. Ricordiamo che la Statistica descrittiva cerca di sintetizzare i dati in esame non solo attraverso tabelle e grafici, ma anche tramite singole quantità numeriche, gli **indici**, chiamati anche **statistiche**. Queste sono grandezze calcolate a partire dai dati ed essenzialmente si suddividono in due grandi famiglie:

- **indici di posizione**, che hanno come obiettivo individuare il “centro” dell'insieme dei dati, a cui è dedicata la presente sezione
- **indici di variabilità**, che hanno come obiettivo quantificare la dispersione dei dati attorno ad un determinato “centro”, a cui è dedicata la prossima sezione

Definizione Sia dice **media** (o anche media campionario quando i dati provengono da un campione) di n dati $x_1, \dots, x_n$ e si denota con $\bar{x}$ la quantità'

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

6.5.2.3 Indici di dispersione

Gli **indici di dispersione** o variabilità hanno come obiettivo proprio *quantificare* tale concentrazione/dispersione dei dati

Varianza Tra gli indici di variabilità, i più importanti sono quelli che usano come valore centrale la *media*. Fra questi indici il più noto è la **varianza**. Prima di darne la definizione è utile introdurre alcune notazioni. Si chiama scarto (o deviazione) di un dato dalla media la quantità'

$$x_i - \bar{x}$$

Si chiamano rispettivamente scarto assoluto (o deviazione assoluta) e scarto quadratico (o deviazione quadratica) le quantità'

$$|x_i - \bar{x}| \quad (x_i - \bar{x})^2$$

Gli indici che misurano lo scarto dalla media si ottengono sommando gli scarti (assoluti o quadratici) dalla media stessa

Definizione Si dice **varianza** (o anche varianza campionaria quando i dati provengono da un campione) di n dati $x_1, \dots, x_n$ e si denota con s^2 (o anche s_n^2) la quantità:

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

La radice quadrata della varianza si chiama **deviazione standard** (o **scostamento quadratico medio**):

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Per calcolare la varianza e' spesso preferibile utilizzare la formula seguente:

Teorema: La varianza di un insieme di n dati $x_1, \dots, x_n$ e' data dalla seguente formula alternativa:

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$$

6.5.3 Dati bivariati: correlazione e regressione

6.5.3.1 Insiemi di dati bivariati e frequenza congiunta

Come nel caso unidimensionale, la nozione fondamentale e' quella di **frequenza**, che ora definiamo nel caso di dati bivariati. Per semplicita', nella presente sezione, supponiamo che i dati siano *quantitativi* e *discreti* e che assumano un numero *finito* di valori distinti.

Per ogni coppia (v_i, w_j) definiamo:

- la **frequenza assoluta congiunta** n_{ij} , data dal numero di volte che la coppia (v_i, w_j) e' stata osservata
- la **frequenza relativa congiunta** $f_{ij} = \frac{n_{ij}}{n}$, data dal rapporto tra frequenza assoluta congiunta e numero totale di dati in esame
- la **frequenza percentuale congiunta** p_{ij} data dalla frequenza relativa congiunta espressa in termini percentuali

Tali frequenze possono essere riportate in forma tabellare tramite una **tabella a doppia entrata**, il cui corpo centrale e' costituito dalla matrice $h \times k$ delle frequenze congiunte.

X	Y	w_1	w_2	$\dots$	w_k	n^X
v_1	n_{11}	n_{12}	$\dots$	n_{1k}	n_1^X	
v_2	n_{21}	n_{22}	$\dots$	n_{2k}	n_2^X	
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$	
v_h	n_{h1}	n_{h2}	$\dots$	n_{hk}	n_h^X	
n^Y	n_1^Y	n_2^Y	$\dots$	n_k^Y	n	

6.5.3.2 Coefficiente di correlazione lineare

Per ottenere una misura quantitativa della dipendenza tra due caratteri, introduciamo una nuova statistica: il **coefficiente di correlazione lineare**. Tale indice misura se esista una dipendenza tra i due caratteri e se tale dipendenza possa essere descritta in maniera significativa da una relazione di tipo lineare. Per definire tale indice e' utile introdurre le nozioni di *correlazione positiva* e *negativa*:

- si parla di **correlazione positiva o diretta** quando se uno dei due caratteri assume un valore grande (risp. piccolo) allora anche l'altro carattere assume un valore grande (risp. piccolo)
- si parla di **correlazione negativa o inversa** quando se uno dei due caratteri assume un valore grande (risp. piccolo) allora l'altro carattere assume un valore piccolo (risp. grande).

La definizione di coefficiente di correlazione lineare necessita di alcune notazioni.

Consideriamo un insieme di dati bivariati $\{(x_i, y_i) : i = 1, \dots, n\}$ quantitativi (discreti o continui). Siano $\bar{x}$ e $\bar{y}$ le rispettive medie aritmetiche. Allo scopo di misurare la correlazione positiva/negativa e' naturale considerare il prodotto degli scarti dalla media per ciascuna coppia di dati il prodotto degli *scarti* delle rispettive medie:

$$(x_i - \bar{x})(y_i - \bar{y})$$

Infatti se x_i e' un valore grande rispetto a quelli tipici significa che $x_i - \bar{x}$ e' positivo, se invece x_i e' un valore piccolo rispetto a quelli tipici significa che $x_i - \bar{x}$ e' negativo. Lo stesso discorso vale per y_i . Di conseguenza, se il prodotto degli scarti dalla media e' positivo allora i dati bivariati mostrano una correlazione positiva, se invece il prodotto degli scarti dalla media e' negativo allora i dati bivariati mostrano una correlazione negativa.

In conclusione, se tra i due caratteri esiste una correlazione positiva/negativa c'e' da aspettarsi che la media aritmetica dei prodotti degli scarti di tutte le coppie

$$\text{covarianza} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

lo percepisca, assumendo di conseguenza un valore positivo/negativo, tanto piu' grande in valore assoluto quanto maggiore e' tale correlazione. Prende il nome di **covarianza**, mentre la sua normalizzazione si chiama *coefficiente di correlazione lineare*.

Definizione Sia dato un insieme di dati bivariati $\{(x_i, y_i) : i = 1, \dots, n\}$ quantitativi (discreti o continui). Siano $\bar{x}$ e $\bar{y}$ le rispettive medie aritmetiche. Siano le deviazioni standard s_x e s_y . Si dice **covarianza** (o anche covarianza campionaria quando i dati provengono da un campione) di x e y la quantità

$$s_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Supponiamo ora che s_x e s_y siano entrambi diverse da zero.

Si dice **coefficiente di correlazione lineare** (o anche coefficiente di correlazione campionario quando i dati provengono da un campione) di x e y la quantità

$$\begin{aligned} r_{xy} &= \frac{s_{xy}}{s_x s_y} \\ &= \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}} \end{aligned}$$

Una formula utile per calcolare la covarianza e' la seguente, che generalizza la formula analoga ottenuta per la varianza.

Teorema: La covarianza di un insieme di n dati bivariati $\{(x_i, y_i) : i = 1, \dots, n\}$ quantitativi (discreti o continui) e' data dalla seguente formula alternativa:

$$s_{xy} = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$$

Teorema Il coefficiente di correlazione lineare verifica le seguenti proprietà:

- $-1 \leq r_{xy} \leq 1$
- $r_{xy} = 1$ se e solo se esistono due costanti reali $m \neq 0$ e q t.c.

$$y_i = mx_i + q, \quad \forall i = 1, \dots, n$$

Inoltre il segno di r_{xy} coincide con il segno di m .

6.5.3.3 Metodo dei minimi quadrati e regressione lineare

In questa sezione ci occupiamo del problema di determinare concretamente una relazione lineare in grado di descrivere, seppur approssimativamente, la relazione tra due caratteri. Faremo cio' indipendentemente dal valore assunto da r_{xy} , tuttavia tale relazione lineare sara' chiaramente tanto piu' significativa quanto piu' $|r_{xy}|$ assumerà un valore vicino ad 1.

L'idea per determinare tale retta e' la seguente: abbiamo una nuvola di punti nel piano cartesiano e cerchiamo due numeri reali m e q tali che la retta

$$y = mx + q$$

passi il piu' vicino possibile a tutti i punti (x_i, y_i) . Per ogni punto consideriamo l'*errore relativo* a tale punto (anche detto *errore parziale*), ovvero la differenza tra il valore reale e quello lungo la retta

$$e_i := y_i - mx_i - q$$

Un procedimento che permette di determinare i numeri m e q e' quello dei **minimi quadrati**, che consiste nel minimizzare la somma dei quadrati degli errori parziali

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - mx_i - q)^2$$

La retta che si ottiene procedendo in questo modo si chiama **retta di regressione** (o **retta dei minimi quadrati**).

Teorema: Sia dato un insieme di dati bivariati $\{(x_i, y_i) : i = 1, \dots, n\}$ quantitativi (discreti o continui). Siano $\bar{x}$ e $\bar{y}$ le rispettive medie aritmetiche. Siano le deviazioni standard s_x e s_y e la covarianza s_{xy} . Supponiamo inoltre che $s_x, s_y \neq 0$.

La **retta di regressione** e' data da

$$y = mx + q$$

con

$$m = \frac{s_{xy}}{s_x^2} \quad \text{e} \quad q = \bar{y} - \frac{s_{xy}}{s_x^2} \bar{x}$$

Quindi

$$y = \frac{s_{xy}}{s_x^2} (x - \bar{x}) + \bar{y} \quad (2)$$

6.5.4 Teoremi limite

Sia dunque X una generica variabile aleatoria di cui si vuole stimare il valore atteso.

Per ottenere una "stima" si segue questo classico procedimento della Statistica: si ripete un numero "elevato" di volte l'esperimento aleatorio, ogni volta registrando quale valore ha assunto la variabile aleatoria X . Si ottiene dunque una sequenza di valori numerici

$$x_1 \quad x_2 \quad \cdots \quad x_n \quad (3)$$

La sequenza cosi' ottenuta e' percio un *campione* di dati. Come otteniamo a partire da $x_1, \dots, x_n$ una stima di $\mathbb{E}[X]$? La scelta naturale e' quella di considerare la *media campionaria*

$$\bar{x}_n = \frac{x_1 + x_2 + \cdots + x_n}{n} \quad (4)$$

La media aritmetica del campione $x_1, \dots, x_n$ e' denotata con $\bar{x}_n$ e si chiama *media campionaria*.

6.5.4.1 Successioni di variabili aleatorie i.i.d.

Iniziamo a formalizzare il problema presentato nella sezione precedente.

E' naturale considerare una successione di variabili aleatorie che rappresentano gli ipotetici valori assunti dalla variabile aleatoria di interesse nei vari esperimenti

$$X_1 \quad X_2 \quad \cdots \quad X_n \quad (5)$$

La lettera maiuscola sta dunque ad indicare che gli esperimenti devono ancora essere svolti e le quantita' sono quindi aleatorie. Solo dopo aver eseguito gli esperimenti conosceremo i valori da esse assunti, che saranno indicati con le lettere minuscole $x_1, \dots, x_n$.

La successione $X = (X_1, X_2, \dots, X_n)$ verra indicata anche con il simbolo

$$(X_n)_n \quad (6)$$

Per quanto detto finora e' chiaro che le variabili aleatorie $X_1, X_2, \dots, X_n$ verificano la seguente proprieta':

- Le variabili aleatorie $X_1, X_2, \dots, X_n$ sono denticamente distribuite
- Le variabili aleatorie $X_1, X_2, \dots, X_n$ sono indipendenti

Definizione: $(X_n)_n$ e' una **successione di variabili aleatorie i.i.d** se valgono le seguenti proprieta':

- Le variabili aleatorie $X_1, X_2, \dots, X_n$ sono denticamente distribuite
- Le variabili aleatorie $X_1, X_2, \dots, X_n$ sono indipendenti

6.5.4.2 Legge dei grandi numeri (LGN)

Iniziamo con un risultato preliminare, particolarmente importante.

Lemma (Disuguaglianza di Chebyshev) Sia X una variabile aleatoria con media μ . Allora per ogni $\varepsilon > 0$ vale che:

$$\mathbb{P}(|X - \mu| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2} \quad (7)$$

Ovvero la legge dei grandi numeri, la quale stabilisce che X_n "converge" verso μ quando n tende all'infinito.

Teorema (Legge dei grandi numeri) Sia $(X_n)_n$ una successione di variabili aleatorie i.i.d. con media μ e varianza σ^2 . Allora posto

$$\bar{X}_n = \frac{X_1 + \cdots + X_n}{n} \quad (8)$$

si ha

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow +\infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) = 0 \quad (9)$$

Inoltre vale che

$$\mathbb{P}(|\bar{X}_n - \mu| < \epsilon) \leq \frac{\sigma^2}{\epsilon^2 n} \quad (10)$$

6.5.4.3 Metodo Monte Carlo

La Legge dei grandi numeri e' alla base di un metodo numerico *probabilistico* molto importante, noto come metodo Monte Carlo. Consideriamo il seguente problema.

$$\text{Come si puo' approssimare } \int_a^b f(x)dx, \text{ con } f \text{ funzione integrabile?} \quad (11)$$

Per semplicita' consideriamo il caso in cui $a = 0$ e $b = 1$.

$$\int_0^1 f(x)dx = \mathbb{E}[f(U)]$$

dove U e' una variabile aleatoria uniforme su $[0, 1]$ ($U \sim \text{Unif}(0, 1)$).

Ci siamo dunque ricondotti al problema di stimare il valore atteso della variabile aleatoria $X = f(U)$. Il metodo Monte Carlo consiste nell'approssimare numericamente il valore atteso $\mathbb{E}[f(U)]$ facendo uso della Legge dei grandi numeri.

Piu' precisamente sia $(U_n)_n$ una successione di variabili aleatorie i.i.d. con distribuzione uniforme su $[0, 1]$. Definiamo

$$X_n = f(U_n), \quad \forall \quad (12)$$

Allora $(X_n)_n$ e' ancora una successione di variabili aleatorie i.i.d. con media $\mathbb{E}[f(U)]$.

Quindi per la legge dei grandi numeri

$$\frac{f(U_1) + \cdots + f(U_n)}{n} \xrightarrow{n \rightarrow +\infty} \mathbb{E}[f(U)] = \int_0^1 f(x)dx \quad (13)$$

L'implementazione del metodo Monte Carlo si basa sull'utilizzo dei *generatori aleatori*.

Nell'esempio qui considerato, per approssimare $\mathbb{E}[f(U)]$ si genera una sequenza di numeri casuali con distribuzione uniforme su $(0, 1)$, quindi

$$u_1 \quad u_2 \quad \cdots \quad u_n \quad (14)$$

Tali numeri sono scritti con la lettera minuscola in quanto sono noti, infatti sono i numeri forniti dal generatore aleatorio. Dopodiche', si calcola la quantita'

$$\frac{f(u_1) + \cdots + f(u_n)}{n}$$

Se n e' "elevato" si ottiene una buona approssimazione dell'integrale $\int_0^1 f(x)dx$.

I principali vantaggi rispetto ai metodi deterministici di integrazione numerica sono i seguenti:

- non si richiedono ipotesi di regolarita' sulla funzione integranda f
- l'ordine di convergenza del metodo, che e' $\frac{1}{\sqrt{n}}$ come seguira' dal Teorema centrale del limite, e' indipendente dalla dimensione e l'implementazione del metodo in dimensione maggiore di uno non comporta alcuna difficolta' aggiuntiva.

6.5.4.4 Metodo del gradiente stocastico

Il metodo del gradiente stocastico e' un algoritmo di ottimizzazione che si basa sul metodo Monte Carlo.

Metodo del gradiente Sia $f : \mathbb{R}^d \rightarrow \mathbb{R}$ una funzione differenziabile. Consideriamo il seguente problema di ottimizzazione:

$$\text{Trovare } x^* \in \mathbb{R}^d \text{ punto di minimo di } f : f(x^*) = \min_x f(x) \quad (15)$$

Ricordiamo il gradiente

$$\nabla f(x) = \left(\frac{\partial f}{\partial x_1}(x), \dots, \frac{\partial f}{\partial x_d}(x) \right) \quad (16)$$

Il vettore $\nabla f(x)$ rappresenta l'incremento infinitesimo della funzione f nel punto x .

Vediamo il metodo del gradiente in modo iterativo:

- Si sceglie un punto di partenza $x_0 \in \mathbb{R}^d$
- Per $n = 0, 1, 2, \dots$ si calcola il gradiente $\nabla f(x_n)$ e si aggiorna il punto x_n
- Si ottiene cosi una successione di punti $x_0, x_1, \dots$ che converge verso un punto di minimo di f

$$x_{k+1} = x_k + \alpha p_k$$

con $p_k = -\nabla f(x_k)$, ovvero la direzione di massima discesa, e $\alpha > 0$ un opportuno passo di aggiornamento.

6.5.4.5 Metodo del gradiente stocastico

Il metodo del gradiente stocastico e' un algoritmo di ottimizzazione che si basa sul metodo del gradiente.

Nell'ambito delle reti neurali si e' interessati al problema di ottimizzazione per una particolare funzione f , avente la seguente espressione:

$$f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x), \quad \forall x \in \mathbb{R}^d$$

In altre parole, f e' la media aritmetica di n funzioni qui indicate con $f_1, \dots, f_n$. Il metodo del gradiente applicato ad una tale funzione corrisponde al seguente schema iterativo:

$$x_{k+1} = x_k - \alpha \nabla f(x_k) \quad (17)$$

$$= x_k - \alpha \frac{1}{n} \sum_{i=1}^n \nabla f_i(x_k) \quad (18)$$

Il metodo del gradiente stocastico consiste dunque nell'individuare, ad ogni passo k , un sottoinsieme di addendi in modo casuale; sono tali addendi i soli che vengono utilizzati al passo k per determinare x_{k+1} .

6.5.4.6 Teorema centrale del limite (TCL)

Come nel caso della Legge dei grandi numeri, consideriamo una successione $(X_n)_n$ di variabili aleatorie i.i.d. e indichiamo con μ e σ^2 media e varianza di ciascuna variabile aleatoria X_n . Sia inoltre

$$\bar{X}_n = \frac{X_1 + \cdots + X_n}{n}$$

Grazie alla Legge dei grandi numeri sappiamo che vale la convergenza

$$\bar{X}_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} \mu$$

Il Teorema centrale del limite descrive come avviene questa convergenza, o più precisamente, ci dice qual è approssimativamente la distribuzione di $\bar{X}_n$ per n grande. Prima di enunciare il Teorema centrale del limite, è utile introdurre la variabile aleatoria $\bar{Z}_n$ data da

$$\bar{Z}_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \tag{19}$$

$$= \frac{\frac{1}{n} \sum_{i=1}^n X_i - \mu}{\sigma/\sqrt{n}} \tag{20}$$

La variabile aleatoria $\bar{Z}_n$ si chiama **media campionaria standardizzata**.

Teorema (Teorema centrale del limite) Sia $(X_n)_n$ una successione di variabili aleatorie i.i.d. con media μ e varianza σ^2 . Supponiamo che $\sigma > 0$, allora posto

$$\bar{Z}_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

si ha

$$\lim_{n \rightarrow +\infty} \mathbb{P}(\bar{Z}_n \leq x) = \lim_{n \rightarrow +\infty} F_{\bar{Z}_n}(x) = \Phi(x), \quad \forall x \in \mathbb{R}$$

7 Catene di Markov

7.1 Processi stocastici

Supponiamo di voler descrivere matematicamente una quantità numerica incerta il cui valore evolve nel tempo. Questo corrisponde ad una famiglia di *variabili aleatorie* indicizzate mediante un parametro che è appunto il “tempo”.

Definizione: Sia $(\Omega, \mathbb{P})$ uno spazio di probabilit .

- Si chiama **processo stocastico a tempo discreto** una successione di variabili aleatorie $(X_n)_n$, con $n \in \mathbb{N}$, tutte definite su Ω
- Si chiama **processo stocastico a tempo continuo** una famiglia di variabili aleatorie $(X_t)_t$, tutte definite su Ω

7.2 Catene di Markov a tempo discreto

I processi stocastici a tempo discreto che studieremo si chiamano *catene di Markov a tempo discreto*, dove il termine “catene” fa proprio riferimento alla particolare struttura di dipendenza tra le variabili aleatorie del processo.

Definizione: Sia chiama **catena di Markov (a tempo discreto)** una successione di variabili aleatorie $(X_n)_n$ che verifica la seguente proprieta' di Markov:

- Le variabili aleatorie $X_1, \dots, X_n$ sono discrete e il loro supporto e' contenuto nello stesso insieme $\mathcal{S}$ discreto (cioe' finito o al piu' infinito numerabile), ovvero

$$\mathcal{S}_{X_1} \subset \mathcal{S} \quad \mathcal{S}_{X_2} \subset \mathcal{S} \quad \dots \quad \mathcal{S}_{X_n} \subset \mathcal{S} \quad (21)$$

$\mathcal{S}$ si chiama lo **spazio degli stati** della catena di Markov.

- (**Proprieta' di Markov:** dipendente a "catena") Per ogni scelta di $i_1, \dots, i_{n-1}, i, j \in \mathcal{S}$ (non necessariamente distinti) vale l'uguaglianza

$$\mathbb{P}(X_{n+1} = j | X_n = i, X_{n-1} = i_{n-1}, \dots, X_1 = i_1) = \mathbb{P}(X_{n+1} = j | X_n = i)$$

La quantita'

$$\pi_{ij} = \mathbb{P}(X_{n+1} = j | X_n = i)$$

si chiama **probabilit  di transizione all'istante n dallo stato i allo stato j** .

I valori $i_1, \dots, i_{n-1}, i$ rappresentano la *storia* del processo fino all'istante n . Inoltre $i_1, \dots, i_{n-1}$ sono i *valori passati*, mentre i e' il *valore presente*. La proprieta' di Markov afferma che, per determinare la probabilit  che al passo $n + 1$ si verifichi l'evento $X_{n+1} = j$, non e' necessario conoscere tutta la storia del processo fino all'istante n , ma e' sufficiente conoscere il solo valore presente i ; infatti X_{n+1} e' il *valore futuro*.

$$\mathbb{P}(\text{"futuro"} | \text{"presente e passato"}) = \mathbb{P}(\text{"futuro"} | \text{"presente"})$$

7.3 Catene di Markov omogenee e a stati finiti

Nel seguito ci occuperemo solamente di una classe particolare e molto importante di catene di Markov, ovvero le *catene di Markov omogenee* e a stati finiti, che ora definiamo.

Definizione: Sia $(X_n)_n$ una catena di Markov.

- Si dice che $(X_n)_n$ e' **omogenea (nel tempo)** se le **probabilita' di transizione non dipendono da n** . In tal caso scriveremo π_{ij} invece di $\pi_{ij}(n)$, e si dice che π_{ij} e' la **probabilita' di transizione dallo stato i allo stato j** .
- Si dice che $(X_n)_n$ e' a **stati finiti** se lo spazio degli stati $\mathcal{S}$ e' finito, ovvero se esiste un numero naturale N t.c. $\mathcal{S} = \{1, 2, \dots, N\}$ (ovvero indichiamo con N la cardinalita' di $\mathcal{S}$). Spesso supporremo che $\mathcal{S}$ sia dato da $\mathcal{S} = \{1, 2, \dots, N\}$, oppure da $\mathcal{S} = \{0, 1, \dots, N-1\}$.

La struttura di dipendenza a catena di $(X_n)_n$, nel caso omogeneo e a stati finiti, e' completamente descritta da una matrice quadrata di ordine N , detta matrice di transizione.

Definizione Sia $(X_n)_n$ una catena di Markov omogenea e a stati finiti. Si chiama **matrice di transizione** la matrice $N \times N$ (dove N e' la cardinalita' di $\mathcal{S}$) indicata con Π , le cui componenti sono le probabilita' di transizione:

$$\pi_{ij} = \mathbb{P}(X_{n+1} = j | X_n = i), \quad \forall i, j \in \mathcal{S} \quad (22)$$

con n qualunque, dato che la catena e' omogenea. In altri termini, la probabilita' di transizione π_{ij} corrisponde all'elemento nella riga i e nella colonna j della matrice Π .

La riga i corrisponde quindi alla "densita' discreta di X_{n+1} sapendo che $X_n = i$ ". Questo implica che ogni elemento di Π deve essere un numero appartenente all'intervallo $[0, 1]$, in quanto corrisponde ad una probabilita' (condizionata). Inoltre, la somma degli elementi di una qualsiasi riga deve essere uguale a 1. In altri termini, Π deve verificare le proprieta' riportate nel seguente teorema.

Teorema: Sia Π la matrice di transizione di una catena di Markov omogenea e a stati finiti. Allora Π verifica le seguenti proprieta':

- $\pi_{ij} \in [0, 1]$, per ogni $i, j \in \mathcal{S}$
- $\sum_{j \in \mathcal{S}} \pi_{ij} = 1$, per ogni $i \in \mathcal{S}$

Rappresentazione grafica di una catena di Markov Una catena di Markov omogenea e a stati finiti puo' essere rappresentata graficamente mediante un *grafo orientato* costruito nel modo seguente:

- ogni stato $i \in \mathcal{S}$ corrisponde ad un nodo del grafo
- ogni probabilita' di transizione π_{ij} corrisponde ad un arco orientato che va dal nodo i al nodo j , con peso pari a π_{ij}

In tal caso si dice che la successione di *variabili aleatorie* $(X_n)_n$ e' una *passeggiata aleatoria* (in inglese *random walk*) sul grafo.

7.3.1 Probabilità di transizione in più passi

Sia $(X_n)_n$ una catena di Markov omogenea e a stati finiti, con matrice di transizione Π . Dalla definizione di $(X_n)_n$ sappiamo quanto vale la probabilità condizionata

$$\mathbb{P}(X_{n+1} = j | X_n = i)$$

Infatti è data da π_{ij} , ovvero dall'elemento nella riga i e nella colonna j della matrice di transizione Π .

Ma invece quanto vale la probabilità condizionata

$$\mathbb{P}(X_{n+2} = j | X_n = i) = ?$$

O più in generale

$$\mathbb{P}(X_{n+m} = j | X_n = i) = ?$$

Tale probabilità (che nel caso omogeneo non dipende da n) si indica con $\pi_{ij}^{(m)}$ e chiama **probabilità di transizione dallo stato i allo stato j in m passi**.

Definizione: Sia $(X_n)_n$ una catena di Markov omogenea e a stati finiti. Per ogni intero $m \geq 0$ poniamo (con n qualsiasi)

$$\pi_{ij}^{(m)} = \mathbb{P}(X_{n+m} = j | X_n = i), \quad \forall i, j \in \mathcal{S}$$

$\pi_{ij}^{(m)}$ si chiama **probabilità di transizione dallo stato i allo stato j in m passi**.

Quando $m = 0$ oppure $m = 1$ la probabilità di transizione in m passi si riduce alla probabilità di transizione definita in precedenza.

Proposizione Sia $(X_n)_n$ una catena di Markov omogenea e a stati finiti e omogenea.

- Per $m = 0$, $\pi_{ij}^{(0)}$ è data da

$$\pi_{ij}^{(0)} = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}$$

Quindi la matrice di componenti $\pi_{ij}^{(0)}$ è la matrice identità I di ordine N .

- Per $m = 1$, $\pi_{ij}^{(1)}$ è data da

$$\pi_{ij}^{(1)} = \pi_{ij}$$

Quindi la matrice di componenti $\pi_{ij}^{(1)}$ è la matrice di transizione Π .

Il seguente teorema fornisce una formula per il calcolo di $\pi_{ij}^{(m)}$ per ogni $m \geq 0$.

Teorema: Sia $(X_n)_n$ una catena di Markov omogenea e a stati finiti. Per ogni intero m la matrice dei componenti $\pi_{ij}^{(m)}$ è data da

$$\Pi^m = \underbrace{\Pi \cdot \Pi \cdot \dots \cdot \Pi}_{m \text{ volte}}$$

Calcolo diretto di $\pi_{ij}^{(m)}$ Dal Teorma sappiamo che per calcolare $\pi_{ij}^{(m)}$ e' sufficiente calcolare la matrice Π^m . Vediam oora invece un modo alternativo piu' diretto he si basa sull'utilizzo del grafo orientato associato a $(X_n)_n$.

Vediamolo nel caso in cui $m = 2$. Sappiamo che $\pi_{ij}^{(2)}$ e' dato da

$$\begin{aligned}\pi_{ij}^{(2)} &= \mathbb{P}(X_{n+2} = j | X_n = i) \\ &= \sum_{k \in \mathcal{S}} \mathbb{P}(X_{n+2} = j, X_{n+1} = k | X_n = i) \\ &= \sum_{k \in \mathcal{S}} \mathbb{P}(X_{n+2} = j | X_{n+1} = k, X_n = i) \cdot \mathbb{P}(X_{n+1} = k | X_n = i) \\ &= \sum_{k \in \mathcal{S}} \pi_{kj} \cdot \pi_{ik}\end{aligned}$$

Ovvero $\pi_{ij}^{(2)}$ e' dato dalla somma, per ogni $k \in \mathcal{S}$, del prodotto tra la probabilita' di transizione dallo stato i allo stato k e la probabilita' di transizione dallo stato k allo stato j .

In generale, per calcolare $\pi_{ij}^{(m)}$ con m qualunque si procede come segue:

- a partire dal grafo, si trovano tutti i cammini che portano da i a j in m passi
- la probabilita' di ogni cammino e' il prodotto delle probabilita' lungo gli archi del cammino stesso
- $\pi_{ij}^{(m)}$ e' la somma delle probabilita' di tutti i cammini da i a j in m passi

7.3.2 Classi comunicanti

Definizione: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti. Fissiamo due stati $i, j \in \mathbb{S}$ (non necessariamente $i \neq j$).

Si dice che j e' **avvessibile da** i se esiste $m \geq 0$ t.c.

$$\pi_{ij}^{(m)} > 0$$

In tal caso scriviamo

$$i \rightsquigarrow j \tag{23}$$

Nei grafi vuol dire che il nodo i e' connesso al nodo j .

Nel caso $i \neq j$ si ha che $i \rightsquigarrow j$ se e solo se esiste un cammino di probabilita' positiva che conduce da i a j .

Teorema: La due affermazioni seguenti sono equivalenti se $i \neq j$:

- $i \rightsquigarrow j$
- esiste un intero $m \geq 1$ ed esiste un cammino $i_1 \rightarrow i_2 \rightarrow \dots \rightarrow i_{m+1}$ in m passi t.c. $i_1 = i, i_{m+1} = j$ e

$$\pi_{i_1 i_2} \cdot \pi_{i_2 i_3} \cdot \dots \cdot \pi_{i_m i_{m+1}} > 0$$

Definizione Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti. Fissiamo due stati $i, j \in \mathbb{S}$.

- Gli stati i e j si dicono **comunicanti** se $i \rightsquigarrow j$ e $j \rightsquigarrow i$. In tal caso scriviamo

$$i \longleftrightarrow j$$

Si chiama **classe comunicante** un sottoinsieme di $\mathbb{S}$ costituito da tutti gli stati tra loro comunicanti.

Definizione: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti.

Si dice che $(X_n)_n$ e' **irriducibile** se esiste un'unica classe comunicante, che e' quindi data dall'insieme $\mathcal{S}$ stesso.

7.3.3 Legge di X_n

Sia $(X_n)_n$ una catena di Markov (omogenea e a stati finiti) con matrice di transizione Π . Ci poniamo ora il seguente problema.

Qual e' la legge della variabile aleatoria X_n ?

Sappiamo che X_n e' una variabile aleatoria discreta, quindi e' sufficiente determinare supporto e densita' discreta di X_n .

Resta da determinare la densita' discreta p_{X_n} . Supponiamo che lo spazio degli stati $\mathcal{S}$ sia dato dall'insieme $1, 2, \dots, N$. Allora determinare la densita' discreta p_{X_n} significa conoscere la tabella

X_n	1	2	$\dots$	N
p_{X_n}	$p_{X_n}(1)$	$p_{X_n}(2)$	$\dots$	$p_{X_n}(N)$

Pie' precisamente, determinare la densita' discreta p_{X_n} significa conoscere il vettore riga $\vec{p}_{X_n}$ dato da

$$\vec{p}_{X_n} = [p_{X_n}(1) \ p_{X_n}(2) \ \dots \ p_{X_n}(N)] = [\mathbb{P}(X_n = 1) \ \mathbb{P}(X_n = 2) \ \dots \ \mathbb{P}(X_n = N)].$$

Teorema: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti. Allora la distribuzione di X_n e' data dalla seguente formula:

$$\vec{p}_{X_n} = \vec{p}_{X_1} \Pi^{n-1}, \quad \forall n = 1, 2, \dots$$

Si noti in particolare che

$$\vec{p}_{X_n}(j) = \mathbb{P}(X_n = j) = \sum_{i=1}^N \vec{p}_{X_1}(i) \pi_{ij}^{n-1}, \quad \forall j \in \mathcal{S}$$

7.3.4 Distribuzione invariante

Sia X una variabile aleatoria discreta con supporto $\mathcal{S}$. Sappiamo che la distribuzione (o legge) di X e' completamente descritta dal vettore riga $\vec{p}_X$, che contiene i valori assunti dalla densita' discreta di X . Per semplificare la notazione, indichiamo questo vettore con $\vec{v}$. Si noti che il vettore $\vec{v}$ verifica le seguenti proprieta':

1. ogni sua componente è compresa tra 0 e 1;
2. la somma delle sue componenti è uguale a 1.

Definizione Siano Π una matrice di transizione e $\vec{v}$ un vettore che verifica la proprietà 1) e 2) qui sopra.

Si dice che $\vec{v}$ è una **distribuzione invariante** o **stazionaria** o **di equilibrio** (per Π) se

$$\vec{v} = \vec{v}\Pi$$

Teorema: Sia $(X_n)_n$ una catena di Markov omogenea e a stati finiti con matrice di transizione Π .

Supponiamo che la distribuzione di X_1 sia invariante ovvero

$$\vec{p}_{x_1} = \vec{p}_{x_1}\Pi$$

Allora la distribuzione di X_n (qualunque sia n) è ancora data da $\vec{p}_{x_1}$.

7.3.5 Interpretazione della distribuzione invariante

Definizione: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti con matrice di transizione Π .

Si dice che $(X_n)_n$ è regolare se esiste n_0 t.c.

$$\pi_{ij}^{n_0} > 0, \quad \forall i, j \in \mathcal{S}$$

ovvero se la matrice

$$\underbrace{\Pi \dots \Pi}_{n_0 \text{ volte}} = \Pi^{n_0}$$

ha tutte le componenti strettamente positive.

Se una catena di Markov è regolare vale il seguente risultato fondamentale.

Teorema (di convergenza all'equilibrio o ergodico): Sia $(X_n)_n$ una catena di Markov omogenea e a stati finiti con matrice di transizione Π .

Se $(X_n)_n$ è regolare allora esiste un'unica distribuzione invariante $\vec{v}$ t.c. qualunque sia $i \in \mathcal{S}$,

$$\lim_{n \rightarrow +\infty} \pi_{ij}^{(n)} = v_j, \quad \forall j \in \mathcal{S}$$

Inoltre la velocità di convergenza è esponenziale:

$$|\pi_{ij}^n - v_j| \leq Cq^n$$

con $0 \leq q \leq 1$ e C costante positiva.

7.3.6 Google e l'algoritmo PageRank

il nome Google e' stato scelto da Brin e Page in quanto rimanda al nome *googol*, che e' il termine matematico con cui si indica il numero 10^{100} : il motivo e' che questo numero rende l'idea della scala dei problemi che un motore di ricerca deve affrontare.

Google, e in particolare l'algoritmo **PageRank**, si basa sulla struttura "topologica" del web, intesa come grafo orientato in cui ogni nodo corrisponde ad una pagina e ogni freccia rappresenta un link. Tale struttura permette di ordinare le pagine, ovvero creare un ranking delle pagine che e' appunto il compito dell'algoritmo PageRank. Questo ordinamento viene utilizzato per rispondere in maniera rapida e soddisfacente a ciascuna singola *query*. L'algoritmo PageRank nella sua forma attuale non e' chiaramente noto (essendo ovviamente tutelato da copyright), per'o l'idea originale del metodo e' chiara. L'ordinamento delle pagine web fornito dall'algoritmo PageRank si basa sull'assegnazione di un indice di significativita' a ciascuna pagina. Per una generica pagina web A , denotiamo tale indice con $PR(A)$. In particolare, l'indice di significativita' deve soddisfare i due requisiti seguenti:

1. risultare elevato se una pagina e' citata da molte altre pagine
2. risultare elevato se riferito ad una pagina citata da (eventualmente poche) pagine molto significative

Dunque il solo conteggio dei link ad una pagina non pu' essere un buon indice di significativita' (in quanto non soddisfa il secondo requisito). L'indice di significativita' di una pagina A deve essere invece proporzionale agli indici di significativita' delle pagine che conducono ad A .

7.3.7 Esistenza e unicit  della misura invariante

Le catene di Markov irriducibili su uno spazio degli stati finito possiedono l'importante proprieta' di ammettere sempre un'unica distribuzione invariante.

Teorema (di esistenza ed unicit  della distribuzione invariante): Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti.

Se $(X_n)_n$ e' irriducibile allora essa ammette un'unica distribuzione invariante $\vec{v}$.

Definizione: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti con matrice di transizione Π . Definiamo il **periodo di uno stato** $i \in \mathcal{S}$ ponendo

$$d_i := \text{MCD}\{m \geq 1 : \pi_{ij}^{(n)} > 0\}$$

La catena si dice **aperiodica** se $d_i = 1$ per ogni $i \in \mathcal{S}$.

Proposizione: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti. $(X_n)_n$ e regolare se e solo se e' irriducibile e aperiodica.

7.4 Classificazione degli stati

I "salti" da uno stato all'altro che la catena di Markov pu' compiere, secondo le probabilita' π_{ij} , fanno si' che nella catena si crei una diversificazione tra gli stati: stati che non vengono mai raggiunti, stati raggiunti piu' volte, gruppi di stati i cui raggiungimenti si escludono a vicenda, e cosi' via.

Definizione: Sia $C \subset S$ una classe di comunicazione. Diciamo che C e' una **classe chiusa** se per ogni $i \in C$ t.c. $i \rightsquigarrow j$ si ha $j \in C$.

Definizione: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti. Sia $i \in S$.

$$N_i := \sum_{n=1}^{\infty} 1_{\{x_n=i\}}$$

e' il numero totale di visite allo stato i . Lo stato i si dice

- **transitorio** se $N_i < +\infty$ q.c.
- **ricorrente** se $N_i = +\infty$ q.c.

Teorema: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti.

1. Ogni classe di comunicazione C chiusa e' ricorrente
2. Ogni classe di comunicazione C non chiusa e' transitoria

Proposizione: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti con matrice di transizione Π . Siano $R_1, \dots, R_m$ le classi ricorrenti di $(X_n)_n$.

Allora le distribuzioni invarianti di Π sono tutte e sole quelle della forma

$$\vec{v} = \sum_{\ell=1}^m \alpha_{\ell} \vec{v}^{\ell}$$

dove $\alpha_{\ell} \geq 0$ per ogni $\ell = 1, \dots, m$ e $\sum_{\ell=1}^m \alpha_{\ell} = 1$ con $\vec{v}^{\ell}$ l'unica distribuzione invariante della catena ristretta a R_{ℓ} (con abuso di notazione la identifichiamo con una distribuzione su S ponendo $v_k^{\ell} = 0$ se $j \notin R_{\ell}$).

7.4.1 Problemi di assorbimento

Se si parte da uno stato transitorio si finir'a per essere assorbiti da una classe ricorrente. D'altra parte, la catena di Markov ristretta ad una classe ricorrente e' irriducibile. Se la catena di Markov possiede pi'u classi ricorrenti e' interessante stabilire in quale classe andr'a a finire X_n , o pi'u precisamente calcolare la probabilit'a di essere assorbita da una certa classe ricorrente piuttosto che da un'altra, partendo da uno stato transitorio. Sia

$$T_c := \min\{n \geq 1 : X_n \in C\}$$

l'istante di primo arrivo nella classe C . Per ogni $i \in S$ denotiamo con

$$h_i^{\ell} := \mathbb{P}(T_{R_{\ell}} < +\infty | X_1 = i)$$

la **probabilita' di assorbimento nella classe ricorrente R_{ℓ} partendo da i** .

Teorema: Sia $(X_n)_n$ una catena di Markov omogenea a stati finiti con matrice di transizione Π . Siano $R_1, \dots, R_m$ le classi ricorrenti di $(X_n)_n$. Allora

$$h_i^\ell = \begin{cases} 1 & \text{se } i \in R_\ell \\ 0 & \text{se } i \in R_p, p \neq \ell \\ \sum_{k \in S} \pi_{ik} h_k^\ell & \text{se } i \in S \setminus \{R_1 \cup \dots \cup R_m\} \end{cases}$$