

Introduzione all'apprendimento automatico

Nicolò Giuliani

Indice

1	Introduzione	2
1.1	Di cosa si occupa il Machine Learning?	2
1.1.1	Predizioni	2
1.1.2	Classi di problemi di apprendimento	3
1.2	Features	4
1.3	Alberi di decisione	5
1.3.1	Alberi di decisione: un esempio	6
1.3.2	Costruzione Top-down induttiva	7
1.3.3	Teoria della Informazione (Shannon)	8
1.3.4	Meglio A o B?	9
1.3.5	Il caso continuo	9
1.4	Overfitting	9
1.4.1	Evitare overfitting sugli alberi di decisione	10
1.4.2	Gini's impurity	10
1.4.3	Foreste (Random Forests)	12
1.5	Approccio probabilistico	12
1.5.1	Variabile aleatoria	12
1.5.2	Spazio campionario ed eventi	12
1.5.3	Assiomi della teoria della probabilità	13
1.5.4	Teoremi derivati	13
1.5.5	Variabili aleatorie multivalore	13
1.5.6	Probabilità condizionata	13
1.5.7	Eventi indipendenti	14
1.5.8	Regola di Bayes	14
1.5.9	Posterior, likelihood, prior e marginale	14
1.6	Distribuzione congiunta e classificatori Bayesiani	15
1.6.1	La distribuzione congiunta	15
1.6.2	Uso della distribuzione congiunta	15
1.6.3	Inferenza con la distribuzione congiunta	15
1.6.4	Naïve Bayes: riassunto	16
1.6.5	Tecnica di apprendimento: stima dei parametri (MLE's)	17
1.6.6	Esempio: Naïve Bayes su Play Tennis	17
1.7	Modelli generativi	18
1.7.1	Tecniche generative	18
1.7.2	Limitazioni	18
1.8	Maximum Likelihood Estimation (MLE)	18
1.9	Classificazione documento	20



1 Introduzione

1.1 Di cosa si occupa il Machine Learning?

Si occupa di risolvere problemi complessi tramite tecniche algoritmiche specifiche. L'approccio generale del ML è

- definire una classe di modelli del problema su insieme di **parametri** Θ
- definire una metrica di valutazione, ovvero una misura dell'**errore** dei modelli
- modificare i parametri Θ per minimizzare l'errore sui **dati di training**

Quindi possiamo dire che il machine learning è un procedimento di ottimizzazione.





Il ML tratta di problemi di **ottimizzazione**!

- Il **training set** fa sì che il tuning dei parametri è dato dalla esperienza passata, quindi una sorta di **apprendimento**.
- La **soluzione** spesso non esiste una soluzione in forma chiusa

Utilizziamo **tecniche iterative** per approssimare iterativamente la soluzione.



1.1.1 Predizioni

Attraverso modelli di ML possiamo anche stabilire correlazioni, clusters, ...




1.1.2 Classi di problemi di apprendimento

- Apprendimento supervisionato: inputs + outputs (etichette)
 - classificazione
 - regressione
- Apprendimento non supervisionato: inputs
 - clustering
 - analisi delle componenti
 - autoencoding
- Apprendimento con rinforzo
 - apprendere comportamenti
 - “model free” planning




Molte tecniche differenti


- Modi diversi per definire i modelli
 - alberi di decisione
 - modelli lineari
 - reti neurali
- Differenti funzioni di loss
 - errore quadratico
 - logistic loss
 - cross entropy
 - similarità del coseno
 - margine massimo




alberi di decisione



reti neurali



errore quadratico medio



margine massimo

1.2 Features

Ogni informazione relativa a un dato che ne descrive una sua proprietà è feature (caratteristica).


- Le features sono gli input del processo di apprendimento.
- L'apprendimento è molto sensibile alla scelta delle features.

Determinare delle buone caratteristiche è complesso.

- **Approccio tradizionale:** determinare durante il preprocessing delle buone features, e applicare un metodo semplice ma robusto di apprendimento, ad esempio qualche tecnica lineare.
- **Approccio “deep”:** fornire in input dati grezzi e delegare alla macchina il compito di sintetizzare nuove features (rappresentazione interna).


Deep learning è implementato attraverso reti neurali profonde.

La rete neurale è profonda quando si hanno layers multipli:



Ogni layer sintetizza nuove features in funzione delle precedenti.


Relazione tra le aree di ricerca



L'AI, machine learning, deep learning:

- **Sistemi basati su conoscenza:** prendete un esperto, chiedetegli come risolverebbe il problema e poi provate a mimare il suo comportamento mediante regole logiche
- **Machine-Learning tradizionale:** prendete un esperto, chiedetegli di quali features avrebbe bisogno per risolvere un dato problema, raccogliete un insieme di osservazioni e lasciate alla macchina il compito di apprendere l'associazione
- **Deep-Learning:** liberatevi dell'esperto

Componenti addestrati mediante apprendimento



1.3 Alberi di decisione

Definiamo **training set** un insieme di **esempi di allenamento**

$$\langle x^{(i)}, y^{(i)} \rangle$$

con

- $x^{(i)} \in X$ insieme degli inputs
- $y^{(i)} \in Y$ insieme degli outputs, **ground truth**
- i indice dell'istanza di training

Definiamo **problema** trovare la funzione che “mappa” $x^{(i)}$ a $y^{(i)}$

- Y discreto: problema di classificazione (predizione di una classe)
- Y continuo: problema di regressione (predizione di un valore)


Le tecniche di Machine Learning richiedono la scelta preliminare di uno **spazio di funzioni** H , all'interno del quale cercare la soluzione che **meglio approssima** i dati di training.

Un modello è un modo di specificare e calcolare una funzione nello spazio delle ipotesi H .

1.3.1 Alberi di decisione: un esempio

È un buon giorno per giocare a tennis?

$$H : \text{Outlook} \times \text{Humidity} \times \text{Wind} \times \text{Temp} \rightarrow \text{Play Tennis?}$$



Ogni nodo testa un attributo (feature) X

Ogni arco uscente da un nodo corrisponde a uno dei possibili valori **discreti** di X

Ogni foglia predice la risposta Y (o una probabilità $P(Y|X)$)

- Insieme di input X :
ogni istanza $x \in X$ è un vettore di features del seguente tipo:
 $\langle \text{Humidity}=\text{high}, \text{Wind}=\text{weak}, \text{Outlook}=\text{rain}, \text{Temp}=\text{hot} \rangle$
- Funzione target $f : X \rightarrow Y$
 Y assume valori discreti (booleani)
- Spazio delle ipotesi $H = \{h \mid h : X \rightarrow Y\}$ (nessuna restrizione)
 - vogliamo modellare $h \in H$ con un albero di decisione
 - ogni istanza $x \in X$ definisce un cammino nell'albero che conduce a una foglia etichettata con $y \in Y$, corrispondente alla soluzione predetta

Outlook	Temp	Humidity	Wind	Play
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No


Expressività del modello Definiamo $X_1 \times X_2 \times \dots \times X_n$ con $X_i = \{\text{true}, \text{false}\}$
Possiamo esprimere $Y = X_2 \vee X_5$?

1.3.2 Costruzione Top-down induttiva

Main loop:

1. assegnare al nodo corrente il “miglior” attributo X_i
2. creare un nodo figlio per ogni possibile valore di X_i e propagare i dati verso i figli a seconda del loro valore
3. per ogni nodo figlio, se tutti i dati del training set associati al nodo hanno una stessa etichetta y , marcare il nodo come foglia con etichetta y , altrimenti ripetere dal primo punto

Ma quale è il “miglior” attributo?




Definiamo **entropia** di una variabile aleatoria X

$$H(X) = - \sum_{i=1}^n P(X = i) \log_2 P(X = i)$$

dove n è il numero dei possibili valori di n .

L'entropia misura il **grado di impurità** (disordine) della informazione. È massima ($\log n$) quando X è uniformemente distribuita tra tutti i suoi n valori, e minima (0) quando è concentrata su un singolo valore.



1.3.3 Teoria della Informazione (Shannon)

L'Entropia è la quantità media di informazione prodotta da una sorgente stocastica di dati.

- Un evento con entropia 1 non trasmette Informazioni

$$I(1) = 0$$

- Dati due evento indipendenti con probabilità p_1, p_2 la probabilità congiunta è $p_1 p_2$ ma l'informazione acquisita è la somma delle informazioni dei due eventi indipendenti

$$I(p_1 p_2) = I(p_1) + I(p_2)$$

- Ci aspettiamo che l'informazione sia antimonotona rispetto alla probabilità ed è quindi naturale definire

$$I(p) = -\log(p)$$

Teoria dei codici (Shannon)

L'Entropia misura il numero medio di bits richiesti per trasmettere il valore prodotto da una sorgente stocastica X .

Se gli eventi non hanno la stessa probabilità possiamo migliorare la codifica!!

Entropia di X

$$H(X) = - \sum_{i=1}^n P(X=i) \log_2 P(X=i)$$

Entropia Condizionale di X dato uno specifico $Y = v$

$$H(X|Y=v) = - \sum_{i=1}^n P(X=i|Y=v) \log_2 P(X=i|Y=v)$$

Entropia Condizionale di X dato Y (media ponderata sugli m possibili valori di Y)


$$H(X|Y) = \sum_{v=1}^m P(Y=v) H(X|Y=v)$$

Guadagno Informativo tra X e Y

$$I(X, Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

1.3.4 Meglio A o B?

Misuriamo la riduzione di entropia della variabile target Y conseguente alla conoscenza di un qualche attributo X , cioè il guadagno informativo $I(Y, X)$ tra Y e X .




$$\begin{aligned} H(Y) &= -(29/64) \cdot \log_2(29/64) - (35/64) \cdot \log_2(35/64) = .994 \\ H(Y|A = T) &= -(21/26) \cdot \log_2(21/26) - (5/26) \cdot \log_2(5/26) = .706 \\ H(Y|A = F) &= -(8/38) \cdot \log_2(8/38) - (30/38) \cdot \log_2(30/38) = .742 \\ H(Y|A) &= .706 \cdot 26/64 + .742 \cdot 38/64 = .726 \\ I(Y, A) &= H(Y) - H(Y|A) = .994 - .726 = .268 \end{aligned}$$

Per B otteniamo $H(Y|B) = .872$ e $I(Y, B) = .122$

Quindi, A è migliore!

1.3.5 Il caso continuo

Quando gli attributi sono continui, prendiamo le decisioni in base a opportune soglie (thresholds):



- confrontiamo le varie soglie in base al loro guadagno informativo
- ma come scegliere le soglie candidate?
 - sampling a intervalli discreti prefissati
 - ordinare il train set rispetto a un dato attributo e scegliere come soglie i valori medi tra dati consecutivi


1.4 Overfitting

Consideriamo l'errore relativo all'ipotesi $h \in H$

- sul training set: $\text{error}_{\text{train}}(h)$
- sul data set (globale): $\text{error}_{\mathcal{D}}(h)$

Definiamo **overfitting** quando esiste un'ipotesi $h' \in H$ tale che

$$\text{error}_{\text{train}}(h') < \text{error}_{\text{train}}(h) \quad \text{ma} \quad \text{error}_{\mathcal{D}}(h') > \text{error}_{\mathcal{D}}(h)$$



Il problema? Non conosciamo $\mathcal{D}$! Quindi semplicemente prendiamo i dati a noi disposizione e li dividiamo in:

- training set: per costruire l'ipotesi h
- test set: utilizzato per misurare accuracy e overfitting h

Tipicamente si riserva una ulteriore porzione, il **test set**, per la valutazione finale.

1.4.1 Evitare overfitting sugli alberi di decisione

- **early stopping**: terminare la costruzione dell'albero non appena il miglioramento del modello non è più statisticamente significativo. Ad esempio, quando il guadagno informativo è inferiore ad una certa soglia, o il numero dei dati relativo al nodo è troppo piccolo.
- **post-pruning**: si sviluppa l'intero albero e quindi si procede a potarlo all'indietro.
 - post-pruning finalizzato alla riduzione dell'errore: costruire un albero di decisione completo per il training set, quindi ripetere la seguente operazione finché ogni ulteriore pruning non migliora l'accuratezza della predizione:
 1. per ogni sottoalbero, valutare (sul validation set) l'impatto della sua rimozione sulla accuratezza della classificazione
 2. effettuare (in modo greedy) il pruning del sottoalbero che ottimizza l'accuracy

1.4.2 Gini's impurity

Gini's impurity (coefficiente di Gini) misura la probabilità che un generico elemento sia mal classificato in base alla classificazione corrente (è una possibile alternativa alla nozione di entropia).

Date m categorie, sia f_i la frazione dei dati con etichetta i . Questa è pari alla probabilità che un qualche input appartenga alla categoria i . La probabilità che venga classificato in modo errato è dunque $1 - f_i$, e il coefficiente di Gini è semplicemente la media pesata di questa quantità su


tutte le possibili categorie, cioè

$$\begin{aligned}
 I_G(f) &= \sum_{i=1}^m f_i(1 - f_i) \\
 &= \sum_{i=1}^m (f_i - f_i^2) \\
 &= \sum_{i=1}^m f_i - \sum_{i=1}^m f_i^2 \\
 &= \boxed{1 - \sum_{i=1}^m f_i^2}
 \end{aligned}$$

La metrica è applicata su ogni nodo figlio, e i valori sono sommati in modo pesato, in modo del tutto analogo a quanto avviene per l'entropia, al fine di ottenere una misura della qualità dell'attributo.

Gini: Meglio A o B?

Valutiamo gli split utilizzando il coefficiente di Gini.



$$I_G(A = T) = 1 - (21/26)^2 - (5/26)^2 = .310$$

$$I_G(A = F) = 1 - (8/38)^2 - (30/38)^2 = .332$$

$$I_G(A) = .310 \cdot 26/64 + .332 \cdot 38/64 = .323$$

$$I_G(B = T) = 1 - (18/51)^2 - (33/51)^2 = .456$$

$$I_G(B = F) = 1 - (11/13)^2 - (2/13)^2 = .260$$

$$I_G(B) = .456 \cdot 51/64 + .260 \cdot 13/64 = .416$$

Quindi, anche con Gini, A è migliore!

Vantaggi e svantaggi degli alberi di decisione

Aspetti positivi

- facili da capire: semplici regole logiche, gli alberi possono essere visualizzati
- poco preprocessing è di solito necessario (attenzione però al bilanciamento delle classi)
- costo predittivo molto basso
- può essere utilizzato sia con features discrete che continue

Aspetti negativi

- rischio elevato di overfitting
- selezione degli attributi piuttosto instabile al variare del dataset
- facile costruire alberi profondamente sbilanciati, specialmente in presenza di una classe dominante

1.4.3 Foreste (Random Forests)

Gli alberi di decisione sono abitualmente utilizzati come componenti delle cosiddette Random Forests, dove sono utilizzati con una tecnica ad **ensemble**.

Le tecniche ad “ensemble” sfruttano il principio che un **gran numero** di modelli **sufficientemente scorrelati** che operano come un comitato forniscono di solito risultati predittivi migliori dei singoli componenti.

Garantire la differenziazione degli alberi

- **Bagging**: allenare i modelli su sottoinsiemi random (bags) dei dati di input
- **Feature Randomness**: costruire gli alberi a partire da sottoinsiemi random delle features

1.5 Approccio probabilistico

Siamo interessati ad approssimare funzioni. Invece di calcolare

$$f : X \rightarrow Y$$

possiamo calcolare

$$p : X \rightarrow P(Y|X)$$

1.5.1 Variabile aleatoria

Una **variabile aleatoria** X denota l'esito di un fenomeno riguardo al quale sussiste incertezza, come ad esempio il risultato di un processo stocastico. Ad esempio

- $X = \text{true}$ se uno studente scelto a caso in aula è biondo
- $X = \text{nome dello studente}$
- $X = \text{true}$ se due studenti scelti a caso sono nati lo stesso giorno dell'anno


Definiamo $P(X)$ come la frazione di volte in cui X è vero, in esecuzioni ripetute dell'esperimento.

1.5.2 Spazio campionario ed eventi

- l'insieme Ω dei possibili esiti di un esperimento casuale è detto **spazio campionario** (sample space)
- una variabile aleatoria è una funzione misurabile su Ω : discreta (es. $\Omega \rightarrow \{m, f\}$) o continua (es. $\Omega \rightarrow \mathbb{R}$)
- un **evento** è un qualche sottoinsieme di Ω ; siamo interessati alla probabilità di eventi specifici, anche condizionati da altri eventi

La scelta dello spazio campionario richiede cautela: spesso l'intuizione presuppone (erroneamente) che gli eventi elementari abbiano tutti la stessa probabilità.


Esempio: nel lancio di due dadi il risultato è un numero tra 2 e 12, ma questi valori non hanno tutti la stessa probabilità; conviene invece considerare come spazio campionario tutte le coppie dei valori dei due dadi, e definire X come la somma dei due risultati.



La probabilità $P(A)$ dell'evento A è il rapporto tra l'area di A e l'area dell'intero spazio campionario (supposto uniforme).

1.5.3 Assiomi della teoria della probabilità

$$\begin{aligned}
 0 &\leq P(A) \leq 1 \\
 P(\text{True}) &= 1 \quad P(\text{False}) = 0 \\
 P(A \vee B) &= P(A) + P(B) - P(A \wedge B)
 \end{aligned}$$



1.5.4 Teoremi derivati

Dimostrazioni omesse.

$$P(\neg A) = 1 - P(A)$$

$$P(A) = P(A \wedge B) + P(A \wedge \neg B)$$

1.5.5 Variabili aleatorie multivalore


A è una variabile aleatoria discreta a k valori se può assumere esattamente uno dei valori $\{\nu_1, \nu_2, \dots, \nu_k\}$.

$$\begin{aligned}
 P(A = \nu_i \wedge A = \nu_j) &= 0 \quad \text{se } i \neq j \\
 P(A = \nu_1 \vee A = \nu_2 \vee \dots \vee A = \nu_k) &= 1
 \end{aligned}$$

1.5.6 Probabilità condizionata

La probabilità condizionata dell'evento A dato l'evento B è definita come

$$P(A|B) = \frac{P(A \wedge B)}{P(B)}$$



Corollario (chain rule):

$$P(A \wedge B) = P(B) \cdot P(A|B) = P(A) \cdot P(B|A)$$

1.5.7 Eventi indipendenti

Due eventi A e B sono detti **indipendenti** se

$$P(A|B) = P(A)$$

ovvero l'evento B non ha influenza sull'evento A . Come corollario

$$P(A \wedge B) = P(A) \cdot P(B)$$

e, siccome $P(A \wedge B) = P(B|A) \cdot P(A)$, abbiamo anche $P(B|A) = P(B)$: cioè anche B è indipendente da A .

1.5.8 Regola di Bayes

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)}$$

1.5.9 Posterior, likelihood, prior e marginale

In generale, per ogni i, j

$$P(Y = y_i | X = x_j) = \frac{P(Y = y_i) \cdot P(X = x_j | Y = y_i)}{\sum_i P(Y = y_i) \cdot P(X = x_j | Y = y_i)}$$

dove il denominatore si ottiene marginalizzando (sommando su Y) $P(X = x_j) = \sum_i P(X = x_j, Y = y_i)$. In notazione compatta

$$\underbrace{P(Y|X)}_{\text{posterior}} = \frac{\overbrace{P(X|Y)}^{\text{likelihood}} \cdot \overbrace{P(Y)}^{\text{prior}}}{\underbrace{P(X)}_{\text{marginal likelihood}}}$$

“Marginale” in quanto stiamo marginalizzando (sommando/integrando) su Y .

1.6 Distribuzione congiunta e classificatori Bayesiani

1.6.1 La distribuzione congiunta

1. costruire una tabella con tutte le possibili combinazioni dei valori delle features
2. stimare la probabilità per ogni combinazione di valori

gender	working hours	health	prob (params)
F	≤ 40	poor	0.25
F	≤ 40	rich	0.03
F	> 40	poor	0.04
F	> 40	rich	0.01
M	≤ 40	poor	0.33
M	≤ 40	rich	0.10
M	> 40	poor	0.13
M	> 40	rich	0.11

Date n features booleane, dobbiamo stimare $2^n - 1$ parametri.

1.6.2 Uso della distribuzione congiunta

Disponendo della distribuzione congiunta possiamo stimare la probabilità di **qualunque evento** esprimibile come combinazione logica delle features.

$$P(E) = \sum_{\text{row} \in E} P(\text{row})$$

Esempio: calcoliamo $P(M, \text{poor})$ dalla tabella precedente

$$\begin{aligned} P(M, \text{poor}) &= P(M, \text{poor}, \leq 40) + P(M, \text{poor}, > 40) \\ &= 0.33 + 0.13 = 0.46 \end{aligned}$$

1.6.3 Inferenza con la distribuzione congiunta

È altrettanto semplice calcolare la probabilità condizionata di un evento E_1 dato un altro evento E_2

$$P(E_1|E_2) = \frac{P(E_1 \wedge E_2)}{P(E_2)} = \frac{\sum_{\text{row} \in E_1 \wedge E_2} P(\text{row})}{\sum_{\text{row} \in E_2} P(\text{row})}$$


Riprendiamo l'esempio precedente e calcoliamo $P(M|\text{poor})$

$$P(M|\text{poor}) = \frac{P(M, \text{poor})}{P(\text{poor})} = \frac{0.46}{0.75} = 0.61$$

Probabilità condizionata vs. learning

Abbiamo appena visto che la conoscenza della distribuzione congiunta permette di calcolare la probabilità condizionata. **Fine della storia?**

Esempio: il caso di MNIST



- immagini di 28×28 pixels in scala di grigi che rappresentano esempi di cifre da 0 a 9 scritte a mano
- 60.000 immagini di training più altre 10.000 immagini di testing

Nel caso delle immagini ogni pixel è una feature, quindi una immagine di 28×28 pixels è rappresentata da un vettore di 784 features.

⇒ Abbiamo molte più righe che esempi di training. Un sacco di configurazioni non sono coperte dal training set.

Indipendenza condizionale

Due eventi X_i e X_j sono **indipendenti dato** Y se

$$P(X_i|X_j, Y) = P(X_i|Y)$$

Naïve Bayes

Per la **chain rule**

$$P(X_1, X_2|Y) = P(X_1|X_2, Y) \cdot P(X_2|Y)$$

e per l'**indipendenza condizionale**

$$P(X_1, X_2|Y) = P(X_1|Y) \cdot P(X_2|Y)$$

In generale

$$P(X_1, X_2, \dots, X_n|Y) = \prod_i P(X_i|Y)$$

Quanti parametri per $P(X_1, \dots, X_n|Y)$ (nel caso booleano)?

- senza indipendenza condizionale
- per Naïve Bayes

1.6.4 Naïve Bayes: riassunto

Bayes rule

$$P(Y = y_i|X_1, \dots, X_n) = \frac{P(Y = y_i) \cdot P(X_1, \dots, X_n|Y = y_i)}{P(X_1, \dots, X_n)}$$

Naïve Bayes

$$P(Y = y_i | X_1, \dots, X_n) = \frac{P(Y = y_i) \cdot \prod_j P(X_j | Y = y_i)}{P(X_1, \dots, X_n)}$$

Classificazione di un nuovo dato $x_{\text{new}} = \langle x_1, \dots, x_n \rangle$

$$Y_{\text{new}} = \arg \max_{y_i} P(Y = y_i) \cdot \prod_j P(X_j = x_j | Y = y_i)$$

1.6.5 Tecnica di apprendimento: stima dei parametri (MLE's)

Variabili aleatorie discrete X_i, Y .

Training (*maximum likelihood estimates*): per tutti i valori y_k di Y , stimare

$$\pi_k = P(Y = y_k) = \frac{\#_D\{Y = y_k\}}{|D|}$$

per ogni possibile valore x_{ij} di X_i , stimare

$$\theta_{ijk} = P(X_i = x_{ij} | Y = y_k) = \frac{\#_D\{X_i = x_{ij} \wedge Y = y_k\}}{\#_D\{Y = y_k\}}$$

dove $\#_D\{\cdot\}$ indica il numero di istanze del dataset D che soddisfano la condizione, e $|D|$ è la dimensione del dataset.

Classificazione di $a_{\text{new}} = \langle a_1, \dots, a_n \rangle$

$$\begin{aligned} Y_{\text{new}} &= \arg \max_{y_k} P(Y = y_k) \cdot \prod_i P(X_i = a_i | Y = y_k) \\ &= \arg \max_k \pi_k \cdot \prod_i \theta_{ijk} \end{aligned}$$

supponendo che $a_i = x_{ij}$, cioè che a_i sia il j -esimo tra i possibili valori discreti dell'attributo X_i .

1.6.6 Esempio: Naïve Bayes su Play Tennis

Riprendiamo il training set visto per gli alberi di decisione (Outlook, Temp, Humidity, Wind $\rightarrow$ Play).

Outlook	Temp	Humidity	Wind	Play
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No

Stima dei parametri

$$\pi_{\text{yes}} = 9/14 \quad \pi_{\text{no}} = 5/14$$

	Y = yes	Y = no
θ_{sunny}	2/9	3/5
θ_{cool}	3/9	1/5
θ_{high}	3/9	4/5
θ_{strong}	3/9	3/5

Predizione Nuova istanza: Outlook=Sunny, Temp=Cool, Humidity=High, Wind=Strong.
Dobbiamo calcolare

$$\arg \max_{y \in \{\text{yes}, \text{no}\}} p(y) \cdot p(\text{sunny}|y) \cdot p(\text{cool}|y) \cdot p(\text{high}|y) \cdot p(\text{strong}|y)$$

ovvero confrontare

$$\begin{aligned} \pi_{\text{yes}} \cdot \theta_{\text{sunny}, \text{yes}} \cdot \theta_{\text{cool}, \text{yes}} \cdot \theta_{\text{high}, \text{yes}} \cdot \theta_{\text{strong}, \text{yes}} &= \frac{9}{14} \cdot \frac{2}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} = .0053 \\ \pi_{\text{no}} \cdot \theta_{\text{sunny}, \text{no}} \cdot \theta_{\text{cool}, \text{no}} \cdot \theta_{\text{high}, \text{no}} \cdot \theta_{\text{strong}, \text{no}} &= \frac{5}{14} \cdot \frac{3}{5} \cdot \frac{1}{5} \cdot \frac{4}{5} \cdot \frac{3}{5} = .0205 \end{aligned}$$

No!

1.7 Modelli generativi

1.7.1 Tecniche generative


Ci interessa calcolare

$$P(Y = y_i \mid X_1, \dots, X_n)$$

La regola di Bayes ci permette di invertire il problema in **data la categoria calcoliamo la distribuzione dei dati**.

Classificazione di un nuovo dato Classifichiamo un nuovo dato chiedendoci quale delle distribuzioni input è quella che si avvicina di più.

Joint vs Naive La distribuzione delle immagini che ci interessa nel esempio mnist consiste in uno spazio da 784 dimensioni. Dato che questo è irrealizzabile utilizziamo l'approccio naive che assume che tutte le features sono indipendenti, riducendo il problema a



$$P(X_j \mid Y = y_i) \quad j = 1, \dots, n$$

1.7.2 Limitazioni

- In alcuni casi in MLE possiamo avere $P(X_i \mid Y) = 0$
- L'approccio naive assume che due eventi sono indipendenti tra loro, e se fossero dipendenti?

1.8 Maximum Likelihood Estimation (MLE)

$$\pi_k = P(Y = y_k) = \frac{\#\mathcal{D}\{Y = y_k\}}{|\mathcal{D}|}$$

$$\theta_{ijk} = P(X_i = x_{ij} \mid Y = y_k) = \frac{\#\mathcal{D}\{X_i = x_{ij} \wedge Y = y_k\}}{\#\mathcal{D}\{Y = y_k\}}$$

Perché? Supponiamo di lanciare una moneta (truccata) 10 volte, otteniamo 6 testa (H) e 4 code (T), possiamo naturalmente concludere che

$$\begin{aligned}P(H) &= .6 \\ P(T) &= .4\end{aligned}$$

Supponiamo ora di avere due possibilità:

1. la moneta è reale, quindi $P(H) = .5$ e $P(T) = .5$
2. la moneta è falsa, quindi $P(H) = .7$ e $P(T) = .3$

Basandoci sulle nostre osservazioni, quale è il nostro caso?

La distribuzione di **Bernoulli** abbiamo 2 possibili output 0 o 1, con probabilità θ e $1 - \theta$. Sia X^n il numero di 0 in una sequenza di n lanci: X^n segue una **distribuzione binomiale**

$$P(X^n = \alpha_0 \mid \theta) = \binom{n}{\alpha_0} \cdot \theta^{\alpha_0} \cdot (1 - \theta)^{\alpha_1}$$

dove $\alpha_1 = n - \alpha_0$ è il numero di 1 nella sequenza (ovvero $\alpha_0 + \alpha_1 = n$).

Continiamo l'esempio di prima $n = 10$, $\alpha_0 = 6$ e $\alpha_1 = 4$.

Se $\theta = .5$ e $1 - \theta = .5$

$$P(X^n = 6 \mid \theta) = \binom{n}{\alpha_0} \cdot \theta^{\alpha_0} \cdot (1 - \theta)^{\alpha_1} = \binom{10}{6} \cdot \left(\frac{1}{2}\right)^6 \cdot \left(\frac{1}{2}\right)^4 = .205$$

Se $\theta = .7$ e $1 - \theta = .3$

$$P(X^n = 6 \mid \theta) = \binom{n}{\alpha_0} \cdot \theta^{\alpha_0} \cdot (1 - \theta)^{\alpha_1} = \binom{10}{6} \cdot \left(\frac{7}{10}\right)^6 \cdot \left(\frac{3}{10}\right)^4 = .200$$

Quindi $\theta = .5$ è leggermente più verosimile di $\theta = .7$.

Qual è il valore più verosimile per θ ?

Calcoliamo MLE

$$\begin{aligned}\hat{\theta} &= \arg \max_{\theta} P(X^n = \alpha_0 \mid \theta) = \\ &= \arg \max_{\theta} \theta^{\alpha_0} \cdot (1 - \theta)^{\alpha_1}\end{aligned}$$

In modo equivalente possiamo cercare il θ che massimizza il logaritmo dell'espressione precedente

$$\ln(\theta^{\alpha_0} \cdot (1 - \theta)^{\alpha_1}) = \alpha_0 \ln(\theta) + \alpha_1 \ln(1 - \theta)$$

Derivando rispetto a θ otteniamo

$$\frac{\alpha_0}{\theta} - \frac{\alpha_1}{1 - \theta} = \frac{\alpha_0 - \alpha_0\theta - \alpha_1\theta}{\theta \cdot (1 - \theta)}$$

che si annulla per

$$\theta = \frac{\alpha_0}{\alpha_0 + \alpha_1} = \frac{\alpha_0}{n}$$

Caso multivariabile Distribuzione discreta (es. lancio di un dado): k possibili esiti $\{1, 2, \dots, k\}$ con probabilità θ_i dove $\sum_i \theta_i = 1$.
Sequenza di n lanci: **distribuzione multinomiale**

$$P(X^n = \alpha_i \mid \theta) = c_{\alpha_i} \prod_i \theta_i^{\alpha_i}$$

dove α_i è il numero di i nella sequenza e c_{α_i} è una costante combinatoria che non dipende da θ .

$$\text{MLE : } \theta_i = \frac{\alpha_i}{\sum_i \alpha_i} = \frac{\alpha_i}{n}$$

1.9 Classificazione documento

pagina 106