

Introduzione all'apprendimento automatico

Nicolò Giuliani

Indice

0	Introduzione	2
0.1	Di cosa si occupa il Machine Learning?	2
0.1.1	Predizioni	2
0.1.2	Classi di problemi di apprendimento	3
0.2	Features	4
0.3	Alberi di decisione	5
0.3.1	Alberi di decisione: un esempio	6
0.3.2	Costruzione Top-down induttiva	7
0.3.3	Teoria della Informazione (Shannon)	8
0.3.4	Meglio A o B?	9
0.3.5	Il caso continuo	9
0.4	Overfitting	9


0 Introduzione

0.1 Di cosa si occupa il Machine Learning?

Si occupa di risolvere problemi complessi tramite tecniche algoritmiche specifiche. L'approccio generale del ML è

- definire una classe di modelli del problema su insieme di **parametri Θ**
- definire una metrica di valutazione, ovvero una misura dell'**errore** dei modelli
- modificare i parametri Θ per minimizzare l'errore sui **dati di training**

Quindi possiamo dire che il machine learning è un procedimento di ottimizzazione.




Il ML tratta di problemi di **ottimizzazione**!

- Il **training set** fa sì che il tuning dei parametri è dato dalla esperienza passata, quindi una sorta di **apprendimento**.
- La **soluzione** spesso non esiste una soluzione in forma chiusa

Utilizziamo **tecniche iterative** per approssimare iterativamente la soluzione.




0.1.1 Predizioni

Attraverso modelli di ML possiamo anche stabilire correlazioni, clusters, ...




0.1.2 Classi di problemi di apprendimento

- Approfondimento supervisionato: inputs + outputs (etichette)
 - classificazione
 - regressione
- Approfondimento non supervisionato: inputs
 - clustering
 - analisi delle componenti
 - autoencoding
- Approfondimento con rinforzo
 - apprendere comportamenti
 - “model free” planning




Molte tecniche differenti


- Modi diversi per definire i modelli
 - alberi di decisione
 - modelli lineari
 - reti neurali
- Differenti funzioni di loss
 - errore quadratico
 - logistic loss
 - cross entropy
 - similarità del coseno
 - margine massimo




alberi di decisione



reti neurali



errore quadratico medio



margine massimo

0.2 Features

Ogni informazione relativa a un dato che ne descrive una sua proprietà è feature (caratteristica).


- Le features sono gli input del processo di apprendimento.
- L'apprendimento è molto sensibile alla scelta delle features.

Determinare delle buone caratteristiche è complesso.

- **Approccio tradizionale:** determinare durante il preprocessing delle buone features, e applicare un metodo semplice ma robusto di apprendimento, ad esempio qualche tecnica lineare.
- **Approccio “deep”:** fornire in input dati grezzi e delegare alla macchina il compito di sintetizzare nuove features (rappresentazione interna).


Deep learning è implementato attraverso reti neurali profonde.

La rete neurale è profonda quando si hanno layers multipli:



Ogni layer sintetizza nuove features in funzione delle precedenti.


Relazione tra le aree di ricerca



L'AI, machine learning, deep learning:

- **Sistemi basati su conoscenza:** prendete un esperto, chiedetegli come risolverebbe il problema e poi provate a mimare il suo comportamento mediante regole logiche
- **Machine-Learning tradizionale:** prendete un esperto, chiedetegli di quali features avrebbe bisogno per risolvere un dato problema, raccogliete un insieme di osservazioni e lasciate alla macchina il compito di apprendere l'associazione
- **Deep-Learning:** liberatevi dell'esperto

Componenti addestrati mediante apprendimento



0.3 Alberi di decisione

Definiamo **training set** un insieme di **esempi di allenamento**

$$\langle x^{(i)}, y^{(i)} \rangle$$

con

- $x^{(i)} \in X$ insieme degli inputs
- $y^{(i)} \in Y$ insieme degli outputs, **ground truth**
- i indice dell'istanza di training

Definiamo **problema** trovare la funzione che “mappa” $x^{(i)}$ a $y^{(i)}$

- Y discreto: problema di classificazione (predizione di una classe)
- Y continuo: problema di regressione (predizione di un valore)


Le tecniche di Machine Learning richiedono la scelta preliminare di uno **spazio di funzioni** H , all'interno del quale cercare la soluzione che **meglio approssima** i dati di training.

Un modello è un modo di specificare e calcolare una funzione nello spazio delle ipotesi H .

0.3.1 Alberi di decisione: un esempio

È un buon giorno per giocare a tennis?

$$H : \text{Outlook} \times \text{Humidity} \times \text{Wind} \times \text{Temp} \rightarrow \text{Play Tennis?}$$



Ogni nodo testa un attributo (feature) X

Ogni arco uscente da un nodo corrisponde a uno dei possibili valori **discreti** di X

Ogni foglia predice la risposta Y (o una probabilità $P(Y|X)$)

- Insieme di input X :
ogni istanza $x \in X$ è un vettore di features del seguente tipo:
 $\langle \text{Humidity}=\text{high}, \text{Wind}=\text{weak}, \text{Outlook}=\text{rain}, \text{Temp}=\text{hot} \rangle$
- Funzione target $f : X \rightarrow Y$
 Y assume valori discreti (booleani)
- Spazio delle ipotesi $H = \{h \mid h : X \rightarrow Y\}$ (nessuna restrizione)
 - vogliamo modellare $h \in H$ con un albero di decisione
 - ogni istanza $x \in X$ definisce un cammino nell'albero che conduce a una foglia etichettata con $y \in Y$, corrispondente alla soluzione predetta

Outlook	Temp	Humidity	Wind	Play
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No


Expressività del modello Definiamo $X_1 \times X_2 \times \dots \times X_n$ con $X_i = \{\text{true}, \text{false}\}$
Possiamo esprimere $Y = X_2 \vee X_5$?

0.3.2 Costruzione Top-down induttiva

Main loop:

1. assegnare al nodo corrente il “miglior” attributo X_i
2. creare un nodo figlio per ogni possibile valore di X_i e propagare i dati verso i figli a seconda del loro valore
3. per ogni nodo figlio, se tutti i dati del training set associati al nodo hanno una stessa etichetta y , marcare il nodo come foglia con etichetta y , altrimenti ripetere dal primo punto

Ma quale è il “miglior” attributo?




Definiamo **entropia** di una variabile aleatoria X

$$H(X) = - \sum_{i=1}^n P(X = i) \log_2 P(X = i)$$

dove n è il numero dei possibili valori di n .

L'entropia misura il **grado di impurità** (disordine) della informazione. È massima ($\log n$) quando X è uniformemente distribuita tra tutti i suoi n valori, e minima (0) quando è concentrata su un singolo valore.



0.3.3 Teoria della Informazione (Shannon)

L'Entropia è la quantità media di informazione prodotta da una sorgente stocastica di dati.

- Un evento con entropia 1 non trasmette Informazioni

$$I(1) = 0$$

- Dati due evento indipendenti con probabilità p_1, p_2 la probabilità congiunta è $p_1 p_2$ ma l'informazione acquisita è la somma delle informazioni dei due eventi indipendenti

$$I(p_1 p_2) = I(p_1) + I(p_2)$$

- Ci aspettiamo che l'informazione sia antimonotona rispetto alla probabilità ed è quindi naturale definire

$$I(p) = -\log(p)$$

Teoria dei codici (Shannon)

L'Entropia misura il numero medio di bits richiesti per trasmettere il valore prodotto da una sorgente stocastica X .

Se gli eventi non hanno la stessa probabilità possiamo migliorare la codifica!!

Entropia di X

$$H(X) = - \sum_{i=1}^n P(X=i) \log_2 P(X=i)$$

Entropia Condizionale di X dato uno specifico $Y = v$

$$H(X|Y=v) = - \sum_{i=1}^n P(X=i|Y=v) \log_2 P(X=i|Y=v)$$

Entropia Condizionale di X dato Y (media ponderata sugli m possibili valori di Y)


$$H(X|Y) = \sum_{v=1}^m P(Y=v) H(X|Y=v)$$

Guadagno Informativo tra X e Y

$$I(X, Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

0.3.4 Meglio A o B?

Misuriamo la riduzione di entropia della variabile target Y conseguente alla conoscenza di un qualche attributo X , cioè il guadagno informativo $I(Y, X)$ tra Y e X .




$$\begin{aligned} H(Y) &= -(29/64) \cdot \log_2(29/64) - (35/64) \cdot \log_2(35/64) = .994 \\ H(Y|A = T) &= -(21/26) \cdot \log_2(21/26) - (5/26) \cdot \log_2(5/26) = .706 \\ H(Y|A = F) &= -(8/38) \cdot \log_2(8/38) - (30/38) \cdot \log_2(30/38) = .742 \\ H(Y|A) &= .706 \cdot 26/64 + .742 \cdot 38/64 = .726 \\ I(Y, A) &= H(Y) - H(Y|A) = .994 - .726 = .288 \end{aligned}$$

Per B otteniamo $H(Y|B) = .872$ e $I(Y, B) = .122$

Quindi, A è migliore!

0.3.5 Il caso continuo

Quando gli attributi sono continui, prendiamo le decisioni in base a opportune **soglie** (thresholds):



- confrontiamo le varie soglie in base al loro guadagno informativo
- ma come scegliere le soglie candidate?
 - sampling a intervalli discreti prefissati
 - ordinare il train set rispetto a un dato attributo e scegliere come soglie i valori medi tra dati consecutivi

0.4 Overfitting